

ỦY BAN NHÂN DÂN THÀNH PHỐ HỒ CHÍ MINH

TRƯỜNG ĐẠI HỌC SÀI GÒN



BÁO CÁO TỔNG KẾT

ĐỀ TÀI NGHIÊN CỨU KHOA HỌC CỦA SINH VIÊN

**ỨNG DỤNG MẠNG BAYESIAN (BNS) ĐỂ PHÂN LOẠI
TÍN HIỆU NHẬN THỨC (COGNITIVE LOAD)**

Mã số đề tài: SV2024-89

Nhóm ngành khoa học: KỸ THUẬT

Chủ nhiệm đề tài: **ĐỖ MINH QUÂN**

Thành viên tham gia: **LÊ THỊ MỸ HƯƠNG,
TRẦN BÙI TY TY**

Giảng viên hướng dẫn: **TS. NGUYỄN QUỐC HUY**

Thành phố Hồ Chí Minh, 04/2025

ỦY BAN NHÂN DÂN THÀNH PHỐ HỒ CHÍ MINH

TRƯỜNG ĐẠI HỌC SÀI GÒN

BÁO CÁO TỔNG KẾT

ĐỀ TÀI NGHIÊN CỨU KHOA HỌC CỦA SINH VIÊN

ỨNG DỤNG MẠNG BAYESIAN (BNS) ĐỂ PHÂN LOẠI
TÍN HIỆU NHẬN THỨC (COGNITIVE LOAD)

Mã số đề tài: SV2024-89

Xác nhận của
Chủ tịch hội đồng nghiệm thu
(ký, họ tên)

Chủ nhiệm đề tài
(ký, họ tên)

Thành phố Hồ Chí Minh, 04/2025

MỤC LỤC

DANH MỤC CÁC BẢNG.....	iv
DANH MỤC CÁC HÌNH ẢNH.....	v
DANH MỤC CHỮ VIẾT TẮT.....	vii
TÓM TẮT ĐỀ TÀI.....	ix
PHẦN MỞ ĐẦU	1
1. Lý do chọn đề tài	1
2. Lịch sử nghiên cứu đề tài	1
3. Mục đích và nhiệm vụ nghiên cứu.....	2
4. Đối tượng và phạm vi nghiên cứu.....	3
5. Phương pháp nghiên cứu.....	3
6. Những đóng góp mới của đề tài	5
7. Cấu trúc của đề tài	5
PHẦN NỘI DUNG.....	7
CHƯƠNG 1: CƠ SỞ LÝ THUYẾT	7
1.1. Tải nhận thức (Cognitive Load - CL)	7
1.1.1. Các loại tải nhận thức.	7
1.1.2. Ứng dụng của tải nhận thức trong nghiên cứu.....	10
1.2. Tín hiệu sinh lý trong phân tích tải nhận thức	12
1.2.1. Nhịp tim (HR - Heart Rate) và Khoảng R-R (RR Interval).....	12

1.2.2. Độ dẫn điện da (GSR - Galvanic Skin Response)	13
1.2.3. Nhiệt độ da (Temp - Skin Temperature).....	13
1.2.4. Mối quan hệ giữa các tín hiệu sinh lý trong tải nhận thức	14
1.3. Mạng Bayesian (Bayesian Network - BN).....	15
1.3.1. Định nghĩa mạng Bayesian	15
1.3.2. Cấu trúc của mạng Bayesian	16
1.3.3. Lợi ích và ứng dụng của mạng Bayesian.....	19
1.4. Lựa chọn đặc trưng và Sequential Backward Selection (SBS)	20
CHƯƠNG 2: CÁC CÔNG TRÌNH NGHIÊN CỨU LIÊN QUAN.....	22
2.1 Những vấn đề liên quan đến tải nhận thức.....	22
2.2. Phương pháp đánh giá tải nhận thức truyền thống	23
2.3 Phương pháp đánh giá tải nhận thức bằng máy học	25
2.4 Thách thức nghiên cứu.....	27
CHƯƠNG 3: TẬP DỮ LIỆU VÀ PHƯƠNG PHÁP ĐỀ XUẤT.....	29
3.1. Tổng quan tập dữ liệu	29
3.2. Phương pháp đề xuất	33
3.2.1. Tiền xử lý dữ liệu.....	34
3.2.2. Trích xuất đặc trưng	35
3.2.3. Huấn luyện mô hình và lựa chọn đặc trưng	38
3.2.4. Nhóm các đặc trưng theo từng tín hiệu sinh lý	39

3.2.5. Xây dựng mô hình Mạng Bayesian	40
3.2.6. Đánh giá mô hình.....	42
CHƯƠNG 4: THỰC NGHIỆM VÀ KẾT QUẢ.....	43
4.1. Quy trình thực nghiệm	43
4.1.1. Thực nghiệm 1: Tìm mô hình có hiệu suất cao nhất.	44
4.1.2. Thực nghiệm 2: Xác định các nút và các cạnh.....	47
4.1.3. Thực nghiệm 3: Kiểm tra ảnh hưởng của các biến quan sát đến biến mục tiêu bằng chiến lược vét cạn.	51
4.2. Kết quả thực nghiệm.....	53
4.3. So sánh với các mô hình công trình nghiên cứu	56
KẾT LUẬN VÀ KHUYẾN NGHỊ	58
TÀI LIỆU THAM KHẢO.....	60

DANH MỤC CÁC BẢNG

Bảng 1. 1	Mối quan hệ giữa các tín hiệu.....	14
Bảng 3. 1:	Các đặc trưng được sử dụng trong nghiên cứu.....	35
Bảng 4. 1:	Danh sách mô tả các thực nghiệm chính	43
Bảng 4. 2:	Đánh giá kết quả mô hình khi không sử dụng SMA.	45
Bảng 4. 3:	Đánh giá kết quả mô hình khi sử dụng SMA (window = 3).	45
Bảng 4. 4:	Các đặc trưng được lựa chọn trong mô hình Random Forest.....	47
Bảng 4. 5:	Nhóm các đặc trưng vào các tín hiệu sinh lý.....	48
Bảng 4. 6:	Các thực nghiệm đưa các đặc trưng quan trọng vào từng nhóm.	50
Bảng 4. 7:	Kết quả thực nghiệm chiến lược vét cạn.	51
Bảng 4. 8:	Kết quả độ chính xác của 13 phương pháp từ cuộc thi.[1].....	57

DANH MỤC CÁC HÌNH ẢNH

Hình 1. 1: Bối rối không xác định phương hướng. (Nguồn Internet)	8
Hình 1. 2: Quá tải nhận thức khi bị phân tâm bởi các yếu tố bên ngoài. (Nguồn Internet)..	9
Hình 1. 3: Sau khi đối phó các tình huống bất ngờ dựa vào kinh nghiệm của mình. (Nguồn Internet)	10
Hình 1. 4: Vòng đeo microsoft band 2 được sử dụng để thu thập dữ liệu. (Nguồn Internet)	12
Hình 1. 5: Mạng Bayesian giả định để mô hình hóa nguy cơ mắc chứng mất trí nhớ.[14]	17
Hình 1. 6: Sơ đồ mô tả các ứng dụng của Mạng Bayesian. (Nguồn Internet)	19
Hình 1. 7: Thuật toán giảm đặc trưng lùi dần (SBS)	21
Hình 2. 1: Các tín hiệu ảnh hưởng tới các yếu tố xung quanh.....	22
Hình 2. 2: Câu hỏi thang đo NASA-TLX gồm 6 yếu tố thành phần dùng để đánh giá tải nhận thức [1]	24
Hình 2. 3: Phương pháp đề xuất của Borisov với mô hình máy học. [25].....	25
Hình 2. 4: Phương pháp đề xuất của Jaiswal với mô hình máy học. [26].....	26
Hình 3. 1: Mô tả tập huấn luyện và kiểm tra trong tập dữ liệu	29
Hình 3. 2: Dữ liệu cảm biến của một đối tượng đối với tín hiệu RR.	30
Hình 3. 3: Dữ liệu sau khi trích xuất phân đoạn 30 giây của một đối tượng.	30
Hình 3. 4: Biểu đồ violin so sánh sự phân bố giữa các mức độ nhiệm vụ.	31
Hình 3. 5: Tỷ lệ của hai nhãn "Rest (0)" và "Task (1)" trong tập dữ liệu.	32
Hình 3. 6: Hướng tiếp cận trong nghiên cứu được đề xuất	33
Hình 3. 7: Tín hiệu sau khi áp dụng trung bình trượt.	34
Hình 3. 8: Quy trình trích xuất đặc trưng của tín hiệu GSR.....	37
Hình 3. 9: Quy trình trích xuất đặc trưng của tín hiệu RR.....	38
Hình 3. 10: Quy trình lựa chọn đặc trưng từ các mô hình.	38
Hình 3. 11: Quy trình xây dựng mô hình mạng Bayesian	40

Hình 3. 12: Các tín hiệu sinh lý ảnh hưởng đến nhau.....	41
Hình 4. 1: Đường cong ROC của các mô hình phân loại.	46
Hình 4. 2: Dữ liệu được chuẩn hóa thành dữ liệu rời rạc.	49
Hình 4. 3: Cấu trúc ban đầu của mô hình mạng Bayesian.	49
Hình 4. 4: Hiệu suất mô hình trên tập huấn luyện GroupKFold = 5.....	52
Hình 4. 5: Cấu trúc mạng tối ưu cho tải nhận thức	52
Hình 4. 6: Cấu trúc mạng Bayesian được đề xuất trong nghiên cứu.....	54
Hình 4. 7: Các phương pháp được những người tham gia trong cuộc thi UBIcomp2020.[1]	56

DANH MỤC CHỮ VIẾT TẮT

TỪ VIẾT TẮT	TÊN TIẾNG ANH	TÊN TIẾNG VIỆT
BNs	Bayesian Networks	Mạng Bayesian
CL	Cognitive Load	Tải nhận thức
HR	Heart Rate	Nhịp tim
HRV	Heart Rate Variability	Biến thiên nhịp tim
RR	Respiration Rate	Tần số hô hấp
GSR	Galvanic Skin Response	Độ dẫn điện da
Temp	Skin Temperature	Nhiệt độ da
SNS	Sympathetic Nervous System	Hệ thần kinh giao cảm
PNS	Parasympathetic Nervous System	Hệ thần kinh đối giao cảm
ROC	Receiver Operating Characteristic	Đường cong ROC
AUC	Area Under Curve	Diện tích dưới đường cong
CPT	Conditional Probability Table	Bảng xác suất có điều kiện
DAG	Directed Acyclic Graph	Đồ thị có hướng không chu trình

SEM	Structural Equation Model	Mô hình phương trình cấu trúc
NASA-TLX	NASA Task Load Index	Chỉ số tải nhận thức của NASA
ECT	Elementary Cognitive Task	Nhiệm vụ nhận thức cơ bản
SCR	Skin Conductance Response	Phản ứng điện da
SCL	Skin Conductance Level	Mức độ dẫn điện da
SVM	Support Vector Machine	Máy vector hỗ trợ
CNN	Convolutional Neural Network	Mạng nơ-ron tích chập
RNN	Recurrent Neural Network	Mạng nơ-ron hồi quy
XGBoost	Extreme Gradient Boosting	Thuật toán tăng cường độ dốc cực đại
SBS	Sequential Backward Selection	Lựa chọn đặc trưng lùi dần
SMA	Simple Moving Average	Bộ lọc trung bình trượt
ANS	Autonomic Nervous System	Hệ thần kinh tự chủ

TÓM TẮT ĐỀ TÀI

Trong xã hội thông tin hiện đại, con người luôn phải đối mặt với áp lực lớn lên khả năng nhận thức. Việc phát hiện sớm tải nhận thức không chỉ mang lại lợi ích trong các ứng dụng tương tác giữa con người và máy tính mà còn đóng góp vai trò quan trọng trong việc bảo vệ sức khỏe tinh thần, duy trì sự tập trung và nâng cao hiệu suất công việc. Nghiên cứu này tập trung vào phát hiện tải nhận thức thông qua các tính năng sinh lý được trích xuất từ phân đoạn 30 giây cuối của bộ dữ liệu thu được từ cuộc thi CogLoad@UbiComp2020. Bài báo sẽ phân tích các tín hiệu sinh lý như độ dẫn điện da (GSR), nhịp tim (HRV), nhịp thở (RR), và nhiệt độ cơ thể (Temperature). Nghiên cứu này tập trung vào việc phát hiện tải nhận thức dựa trên các tín hiệu sinh lý, giúp cung cấp một phương pháp đánh giá khách quan và chính xác hơn so với các phương pháp truyền thống như bảng câu hỏi chủ quan. Các đặc trưng sinh lý được trích xuất từ phân đoạn 30 giây cuối của mỗi nhiệm vụ từ bộ dữ liệu được thu thập trong cuộc thi CogLoad @UbiComp2020 – một thách thức khoa học nhằm phát triển các thuật toán phân loại tải nhận thức dựa trên dữ liệu cảm biến. Dựa trên các đặc trưng này, nghiên cứu đã sử dụng Mạng Bayesian để phân loại tải nhận thức, nhằm tìm hiểu mối quan hệ giữa các biến số sinh lý và trạng thái nhận thức với độ chính xác 65,8% và đường cong ROC 66%. Bằng cách ứng dụng phương pháp này, nghiên cứu hướng tới cải thiện khả năng nhận diện và giám sát tải nhận thức theo thời gian thực, tạo tiền đề cho các hệ thống hỗ trợ cá nhân hóa trong giáo dục, y tế và quản lý công việc, giúp tối ưu hóa hiệu suất và bảo vệ sức khỏe tinh thần của người dùng.

PHẦN MỞ ĐẦU

1. Lý do chọn đề tài

Trong lĩnh vực nghiên cứu về nhận thức và sinh lý học, việc đánh giá mức độ tải nhận thức thông qua các tín hiệu sinh lý ngày càng thu hút sự quan tâm. Tuy nhiên, thách thức đặt ra là làm thế nào để xây dựng một mô hình vừa có độ chính xác cao, vừa đảm bảo tính trực quan và dễ diễn giải. Mạng bayesian là một phương pháp tiếp cận tiềm năng, giúp mô hình hóa quan hệ nhân-quả giữa các biến số và dự đoán trạng thái nhận thức dựa trên dữ liệu sinh lý. Không giống như các thuật toán học máy “hộp đen” khó diễn giải, BNs cho phép hiểu rõ hơn về tác động của từng yếu tố, bao gồm nhịp tim, tần số hô hấp, độ dẫn điện da và nhiệt độ cơ thể đến mức độ tải nhận thức. Việc lựa chọn đề tài này xuất phát từ nhu cầu xây dựng một mô hình có khả năng suy luận nhân quả, giúp phân loại tín hiệu chính xác đồng thời làm rõ mối liên hệ giữa các yếu tố sinh lý và nhận thức. Hơn nữa, BNs mang lại tính trực quan và dễ diễn giải hơn so với các mô hình học máy phức tạp khác, giúp hiểu rõ hơn về cơ chế ảnh hưởng của các tín hiệu sinh lý đến nhận thức. Nghiên cứu này không chỉ có ý nghĩa về mặt học thuật mà còn có tiềm năng ứng dụng cao trong các lĩnh vực như giáo dục, y tế, tối ưu hóa hiệu suất làm việc và giám sát sức khỏe tâm lý. Việc so sánh và đánh giá hiệu suất của các phương pháp phân loại tín hiệu nhận thức sẽ giúp xây dựng mô hình dự đoán bằng mạng bayesian, góp phần vào sự phát triển của các hệ thống nhận diện trạng thái nhận thức chính xác và hiệu quả hơn.

2. Lịch sử nghiên cứu đề tài

Năm 2018, Schmalfu và các cộng sự đã tiến hành nghiên cứu về tiềm năng của các thiết bị đeo trong việc phát hiện khối lượng công việc tinh thần dưới các điều kiện hoạt động sinh lý khác nhau [2]. Tuy nhiên, kết quả phân tích thống kê chỉ ra rằng các thiết bị này chưa đủ khả năng xác định chính xác mức độ tải nhận thức, đặc biệt khi có sự tác động của hoạt động thể chất.

Đến năm 2021, Gjoreski và các cộng sự đã thực hiện một nghiên cứu quy mô lớn với 23 đối tượng tham gia thử thách UbiTention tại hội thảo UbiComp 2020 [1]. Mục tiêu của nghiên cứu là so sánh hiệu suất của 13 phương pháp phân loại tín hiệu nhận thức sinh lý khác nhau. Mặc dù đạt được một số kết quả đáng chú ý, nhưng nghiên cứu này vẫn chưa làm rõ được mối liên hệ giữa các đặc trưng của tín hiệu nhận thức, một phần do các phương pháp phân loại được xử lý như một hộp đen, khiến việc diễn giải và hiểu rõ cơ chế phản ứng sinh lý trở nên khó khăn.

Gần đây, Shaposhnyk và Yanushkevich (2023) đã đưa ra một cách tiếp cận mới bằng cách kết hợp Mô hình phương trình cấu trúc (SEM) và mạng Bayesian để phân tích tải nhận thức [3]. Nghiên cứu này sử dụng tín hiệu sinh lý từ tập dữ liệu CogLoad (bao gồm nhịp tim, khoảng thời gian giữa các nhịp tim liên tiếp, độ dẫn điện da và nhiệt độ) để xác định mức độ tải nhận thức, đồng thời tích hợp các bài kiểm tra tính cách HEXACO nhằm đánh giá yếu tố nhân cách ảnh hưởng đến phản ứng nhận thức. Việc sử dụng Mạng Bayesian giúp làm rõ quan hệ nhân quả giữa tín hiệu sinh lý và tải nhận thức, đồng thời tạo nền tảng cho các công cụ giám sát sức khỏe xã hội trong các bối cảnh như đại dịch hoặc di cư hàng loạt.

Những hạn chế trên chính là động lực cho nghiên cứu này, nhằm làm sáng tỏ mối quan hệ nhân quả giữa các đặc trưng tín hiệu sinh lý, từ đó cải thiện tính minh bạch và độ chính xác trong quá trình phân loại tải nhận thức.

3. Mục đích và nhiệm vụ nghiên cứu

Mục đích của nghiên cứu này là xây dựng mô hình mạng Bayesian dựa trên các đặc trưng được chọn nhằm nâng cao hiệu suất phân loại tín hiệu nhận thức. Nghiên cứu tập trung vào việc khai thác mối quan hệ giữa các tín hiệu sinh lý (RR, GSR, HR, Temp) và trạng thái tải nhận thức (rest hoặc task) thông qua mô hình Bayesian.

Về nhiệm vụ nghiên cứu:

- Phân tích và đánh giá các phương pháp hiện có: Tiến hành phân tích và đánh giá các mô hình truyền thống như SVM, Random Forest, Gradient Boosting, CNN, RNN, v.v., nhằm xác định các phương pháp tối ưu trong phân loại tín hiệu nhận thức.
- Phát triển phương pháp mới: Đề xuất một mô hình dựa trên mạng Bayesian, trong đó các tín hiệu sinh lý (RR, GSR, HR, Temp) đóng vai trò quan trọng trong việc phát hiện tải nhận thức.
- Thử nghiệm và đánh giá: Đánh giá hiệu suất của mô hình mạng bayesian nhằm đánh giá khả năng ứng dụng trong phân loại tín hiệu nhận thức.

4. Đối tượng và phạm vi nghiên cứu

Đối tượng nghiên cứu: Nghiên cứu tập trung vào các tín hiệu sinh lý gồm RR (Respiration Rate), GSR (Galvanic Skin Response), HR (Heart Rate), và Temp (Temperature), vốn có ảnh hưởng quan trọng đến việc đánh giá tải nhận thức.

Phạm vi nghiên cứu: Dữ liệu sử dụng trong nghiên cứu được lấy từ CogDatasets, một tập dữ liệu được công bố trong bài báo của Gjoreski cùng các cộng sự “*Cognitive Load Monitoring With Wearables - Lessons Learned From a Machine Learning Challenge*”[1]. Dữ liệu được thu thập từ các thiết bị cảm biến đeo trên người, giúp ghi nhận các tín hiệu sinh lý của người tham gia trong các trạng thái nhận thức khác nhau. Nghiên cứu tập trung vào bài toán phân loại hai trạng thái tải nhận thức: Rest và Load, nhằm xác định một người đang trong trạng thái làm việc hay nghỉ ngơi dựa vào các đặc trưng được trích xuất từ tín hiệu sinh lý.

5. Phương pháp nghiên cứu

Nghiên cứu này đề xuất một phương pháp ứng dụng mạng Bayesian để phân loại trạng thái nhận thức dựa trên tín hiệu sinh lý. Phương pháp tiếp cận được thiết kế

nhằm tối ưu hóa quá trình tiền xử lý, trích xuất đặc trưng và xây dựng mô hình, giúp nâng cao độ chính xác trong việc nhận diện trạng thái nhận thức.

Cụ thể, quy trình tiếp cận của nghiên cứu bao gồm sáu bước chính:

1. Tiền xử lý dữ liệu: Dữ liệu thô từ các cảm biến sinh lý (GSR, RR, HR, Temp) được xử lý với hai phương pháp: giữ nguyên dữ liệu gốc hoặc áp dụng bộ lọc trung bình trượt (window = 3 giây) để làm mượt tín hiệu.
2. Trích xuất đặc trưng: Các đặc trưng thống kê (trung bình, độ lệch chuẩn, độ nhọn, độ lệch, phân vị, phạm vi, đạo hàm) và đặc trưng chuyên gia từ thư viện NeuroKit2 được trích xuất từ dữ liệu đã xử lý.
3. Lựa chọn đặc trưng: Áp dụng thuật toán SBS để chọn tập đặc trưng tối ưu nhằm đạt hiệu suất cao nhất.
4. Nhóm đặc trưng: Các đặc trưng được nhóm theo từng loại tín hiệu sinh lý để đảm bảo thông tin phản ánh đầy đủ từ từng tín hiệu.
5. Xây dựng mô hình: Sử dụng cấu trúc mạng Bayesian để mô hình hóa mối quan hệ giữa các đặc trưng và trạng thái nhận thức.
6. Đánh giá mô hình: Hiệu suất mô hình được đánh giá dựa trên độ chính xác phân loại và đường cong ROC, đồng thời so sánh với các phương pháp khác trong cuộc thi UBIComp 2020.

Phương pháp nghiên cứu này nhằm tối ưu hóa quá trình phân loại tín hiệu nhận thức, đồng thời cung cấp một mô hình biểu diễn mối quan hệ giữa các tín hiệu sinh lý và trạng thái tải nhận thức.

6. Những đóng góp mới của đề tài

Nghiên cứu này đề xuất một phương pháp tiếp cận mới dựa trên mạng Bayesian nhằm phân loại tải nhận thức dựa trên các tín hiệu sinh lý. Bằng cách tận dụng mối quan hệ giữa các đặc trưng được trích xuất từ tín hiệu RR, GSR, HR và Temp, mạng Bayesian có thể mô hình hóa sự tương tác giữa các yếu tố này để cải thiện độ chính xác trong phân loại hai trạng thái nhận thức: Rest và Load. Không những thế, việc xác định các đặc trưng quan trọng có ảnh hưởng lớn đến việc phân loại tín hiệu nhận thức. Một phân quan trọng trong nghiên cứu là xác định các đặc trưng quan trọng nhất để phân loại tải nhận thức. Sử dụng phương pháp Sequential Backward Selection (SBS), nghiên cứu đã tìm ra tập hợp các đặc trưng có ảnh hưởng lớn đến phân loại. Dựa trên kết quả này, nghiên cứu sử dụng mạng Bayesian để khai thác và biểu diễn mối quan hệ giữa các đặc trưng này với nhau để đánh giá hiệu suất và khả năng diễn giải của mô hình mạng này.

7. Cấu trúc của đề tài

Cấu trúc báo cáo tổng kết bao gồm:

Chương 1: Cơ sở lý thuyết

Trình bày các khái niệm liên quan đến tải nhận thức, các tín hiệu sinh lý được sử dụng trong nghiên cứu như nhịp tim (HR), nhịp hô hấp (RR), nhiệt độ cơ thể (Temp) và phản ứng điện da (GSR). Bên cạnh đó, chương này cũng giới thiệu tổng quan về mạng Bayesian, bao gồm nguyên lý hoạt động, ưu điểm và ứng dụng của mô hình trong bài toán phân loại tải nhận thức. Mối quan hệ giữa các tín hiệu sinh lý và mức độ tải nhận thức cũng sẽ được đề cập nhằm làm rõ nền tảng khoa học cho nghiên cứu.

Chương 2: Giới thiệu các công trình nghiên cứu liên quan

Tổng hợp và phân tích các nghiên cứu trước đây về nhận diện tải nhận thức từ tín hiệu sinh lý. Chương này giúp làm rõ những phương pháp đã được áp dụng, những thách thức còn tồn tại và hướng tiếp cận phù hợp để xây dựng mô hình phân loại dựa trên mạng Bayesian. Việc tham khảo các nghiên cứu liên quan không chỉ giúp xác định các kỹ thuật tiền xử lý dữ liệu hiệu quả mà còn cung cấp góc nhìn so sánh giữa các phương pháp khác nhau trong lĩnh vực này.

Chương 3: Tập dữ liệu và phương pháp đề xuất

Mô tả tập dữ liệu được sử dụng trong nghiên cứu, bao gồm nguồn gốc, cách thu thập và các thông tin liên quan đến dữ liệu. Chương này cũng trình bày quy trình tiền xử lý dữ liệu, bao gồm việc loại bỏ nhiễu, trích xuất các đặc trưng thống kê như giá trị trung bình, độ lệch chuẩn, độ lệch, tổng và trung vị. Tiếp theo, mô hình mạng Bayesian được xây dựng và tối ưu hóa để phù hợp với bài toán phân loại tải nhận thức. Phương pháp đánh giá hiệu suất mô hình, bao gồm các chỉ số như độ chính xác, độ nhạy và độ đặc hiệu, cũng được đề cập trong chương này.

Chương 4: Thực nghiệm và kết quả

Trình bày quá trình huấn luyện và kiểm thử mô hình mạng Bayesian trên tập dữ liệu thực nghiệm. Chương này phân tích hiệu suất của mô hình qua các chỉ số đánh giá, đồng thời so sánh kết quả với các phương pháp truyền thống như hồi quy logistic hay cây quyết định. Các biểu đồ trực quan và bảng số liệu sẽ được sử dụng để minh họa kết quả, giúp làm rõ mức độ hiệu quả của phương pháp đề xuất.

PHẦN NỘI DUNG

CHƯƠNG 1: CƠ SỞ LÝ THUYẾT

1.1. Tải nhận thức (Cognitive Load - CL)

Trong đời sống hàng ngày, tải nhận thức không chỉ ảnh hưởng đến việc học tập mà còn tác động đến nhiều hoạt động và quyết định khác. Tải nhận thức ảnh hưởng đến nhiều khía cạnh trong đời sống hàng ngày. Hiểu và quản lý tốt tải nhận thức có thể giúp chúng ta làm việc hiệu quả hơn, giảm căng thẳng và cải thiện chất lượng cuộc sống. Tải nhận thức là khả năng nỗ lực của tinh thần được sử dụng trong bộ nhớ làm việc của một người. Nói một cách đơn giản, đó là số lượng ý muốn bạn cần nỗ lực để hoàn thành một nhiệm vụ cụ thể.

“Tải nhận thức là số lượng suy nghĩ bạn cần tập trung để hoàn thành một nhiệm vụ cụ thể.”

1.1.1. Các loại tải nhận thức.

Định luật tải nhận thức có thể được phân biệt thành ba loại:

- **Tải Nhận Thức Nội Tại (Intrinsic Cognitive Load)**

Tải nhận thức nội tại là loại tải nhận thức liên quan đến độ phức tạp vốn có của nhiệm vụ mà người học phải xử lý. Nó phụ thuộc vào số lượng yếu tố thông tin cần xử lý đồng thời và mức độ tương tác giữa chúng.

Hình 1.1 thể hiện tải nhận thức nội tại nếu nhiệm vụ yêu cầu người thực hiện xử lý nhiều thông tin cùng lúc để định hướng, chẳng hạn như đọc bản đồ phức tạp hoặc giải quyết vấn đề không có hướng dẫn rõ ràng. Khi mức độ phức tạp của nhiệm vụ vượt quá khả năng xử lý của bộ nhớ làm việc, người thực hiện có thể cảm thấy bối rối.



Hình 1. 1: Bối rối không xác định phương hướng. (Nguồn Internet)

Hay khi học lái xe lần đầu có thể rất căng thẳng vì người học phải xử lý nhiều thông tin và thao tác phức tạp cùng lúc. Hậu quả:

- ❖ **Căng thẳng, lo lắng** → Ảnh hưởng tập trung và phản xạ.
- ❖ **Sai sót thao tác** → Quên xi nhan, đạp nhầm ga, mất kiểm soát tốc độ.
- ❖ **Mất tự tin** → Cảm thấy không đủ khả năng lái xe an toàn

Như vậy, tải nhận thức nội tại đóng vai trò quan trọng trong quá trình học tập và thực hiện nhiệm vụ, khi mức độ phức tạp vượt quá khả năng xử lý, nó có thể gây căng thẳng, sai sót và giảm tự tin, đòi hỏi các biện pháp hỗ trợ để giúp người học thích nghi hiệu quả hơn.

- **Tải Nhận Ngoài Ý Muốn (Extraneous Cognitive Load)**

Tải nhận thức ngoài ý muốn là loại tải nhận thức phát sinh từ cách thức thông tin được trình bày hoặc từ các yếu tố không cần thiết trong quá trình học tập hay thực hiện nhiệm vụ. Nó không liên quan đến bản chất của nhiệm vụ mà chủ yếu do thiết kế kém hiệu quả, gây thêm gánh nặng cho bộ nhớ làm việc của người học.



Hình 1. 2: Quá tải nhận thức khi bị phân tâm bởi các yếu tố bên ngoài. (Nguồn Internet)

Tải nhận thức ngoài ý muốn khi lái xe qua khu vực đông đúc do nhiều biển báo, tín hiệu, phương tiện và người đi bộ gây quá tải nhận thức (xem hình 1.2). Hậu quả:

- ❖ **Giảm tập trung** → Dễ bị phân tán bởi yếu tố bên ngoài.
- ❖ **Tăng nguy cơ tai nạn** → Khó nhận diện kịp thời nguy hiểm.
- ❖ **Phản ứng chậm** → Giảm khả năng xử lý tình huống khẩn cấp.

Tải nhận thức ngoài ý muốn làm gia tăng gánh nặng xử lý thông tin, ảnh hưởng đến sự tập trung và phản xạ, do đó cần thiết kế môi trường và hướng dẫn hợp lý để giảm thiểu tác động tiêu cực.

- **Tải Nhận Tinh Túy (Germane Cognitive Load)**

Tải nhận thức tinh túy là loại tải nhận thức có lợi, giúp người học xây dựng và củng cố các cấu trúc kiến thức trong trí nhớ dài hạn. Nó phản ánh nỗ lực tinh thần được sử dụng để hiểu sâu và tổ chức thông tin một cách hiệu quả.



Hình 1. 3: Sau khi đối phó các tình huống bất ngờ dựa vào kinh nghiệm của mình. (Nguồn Internet)

Khi tài xế có kinh nghiệm phải đối phó với tình huống bất ngờ, họ cần sử dụng kinh nghiệm và phản ứng nhanh để xử lý (xem hình 1.3). Hậu quả sẽ gây căng thẳng tạm thời, mệt mỏi, Khi phải đối phó với tình huống bất ngờ, ngay cả tài xế có kinh

Tóm lại, tải nhận thức bao gồm tải nhận thức nội tại, tải nhận thức ngoài ý muốn và tải nhận thức tinh túy, mỗi loại có ảnh hưởng khác nhau đến quá trình học tập và thực hiện nhiệm vụ. Trong khi tải nhận thức nội tại liên quan đến độ phức tạp vốn có của nhiệm vụ, tải nhận thức ngoài ý muốn có thể gây nhiễu và làm giảm hiệu suất, còn tải nhận thức tinh túy giúp tối ưu hóa việc học và xử lý thông tin. Do đó, việc quản lý và điều chỉnh các loại tải nhận thức một cách hợp lý là cần thiết để nâng cao hiệu quả học tập và làm việc.

1.1.2. Ứng dụng của tải nhận thức trong nghiên cứu

Tải nhận thức đóng vai trò quan trọng trong việc đánh giá trạng thái hoạt động trí tuệ và ảnh hưởng trực tiếp đến hiệu suất làm việc cũng như sức khỏe tinh thần của con người. Việc theo dõi và phân loại tải nhận thức giúp các hệ thống hỗ trợ người dùng đưa ra các quyết định điều chỉnh phù hợp nhằm duy trì hiệu suất tối ưu.

Trong nghiên cứu này, việc ứng dụng mạng Bayesian giúp phân loại tải nhận thức bằng cách tận dụng mối quan hệ giữa các tín hiệu sinh lý và trạng thái nhận thức của người dùng. Các ứng dụng chính bao gồm:

- ***Theo dõi trạng thái nhận thức theo thời gian thực***

Hệ thống phân loại tải nhận thức giúp theo dõi trạng thái Rest (nghỉ ngơi) và Task (làm việc) dựa trên các chỉ số sinh lý như nhịp tim (HR), tần số hô hấp (RR), độ dẫn điện da (GSR), nhiệt độ cơ thể (Temp). Mạng Bayesian cho phép đánh giá xác suất trạng thái của người dùng, giúp hệ thống nhận diện khi nào họ đang làm việc căng thẳng hoặc cần nghỉ ngơi.

- ***Cảnh báo và hỗ trợ người dùng***

Khi tải nhận thức vượt ngưỡng an toàn, hệ thống có thể đưa ra cảnh báo kịp thời, nhắc nhở người dùng điều chỉnh nhịp độ làm việc để tránh kiệt sức. Nhờ mô hình xác suất của Mạng Bayesian, hệ thống có thể cá nhân hóa cảnh báo, chẳng hạn: “Xác suất bạn đang làm việc với cường độ cao là 85%. Hãy nghỉ ngơi để duy trì hiệu suất.” hay “Hệ thống phát hiện mức tải nhận thức của bạn đang tăng cao liên tục. Bạn có muốn thực hiện một bài tập thư giãn?”

- ***Ứng dụng trong các hệ thống giám sát và tối ưu hiệu suất làm việc***

Việc phân loại tải nhận thức có thể được áp dụng trong nhiều lĩnh vực như:

- Quản lý hiệu suất nhân viên: Theo dõi mức độ tập trung của nhân viên trong môi trường làm việc căng thẳng.
- Hỗ trợ lái xe an toàn: Nhận diện tình trạng mệt mỏi của tài xế dựa trên dấu hiệu sinh lý để cảnh báo kịp thời.

- Học tập cá nhân hóa: Điều chỉnh tài liệu học tập và bài giảng dựa trên mức tải nhận thức của người học.

Như vậy, ứng dụng Mạng Bayesian trong phân loại tải nhận thức không chỉ giúp theo dõi trạng thái nhận thức mà còn hỗ trợ các hệ thống đưa ra quyết định thông minh nhằm bảo vệ sức khỏe tinh thần và nâng cao hiệu suất công việc.

1.2. Tín hiệu sinh lý trong phân tích tải nhận thức

Tải nhận thức là trạng thái mà hệ thần kinh trung ương phải xử lý một lượng thông tin lớn, dẫn đến sự thay đổi trong hoạt động sinh lý. Các tín hiệu sinh lý được sử dụng phổ biến để phân tích tải nhận thức bao gồm nhịp tim, tần số hô hấp, độ dẫn da và nhiệt độ da. Những tín hiệu này phản ánh hoạt động của hệ thần kinh tự động ANS và có thể được đo lường bằng các thiết bị đeo tay hoặc cảm biến sinh lý [4], [5] như mô tả hình 1.4.



Hình 1. 4: Vòng đeo microsoft band 2 được sử dụng để thu thập dữ liệu. (Nguồn Internet)

1.2.1. Nhịp tim (HR - Heart Rate) và Khoảng R-R (RR Interval)

Nhịp tim (HR) là số lần tim đập trong một phút (*beats per minute - bpm*), trong khi khoảng R-R (RR Interval) là thời gian giữa hai đỉnh sóng R liên tiếp trên tín hiệu điện tim (ECG).

- **Khi tải nhận thức tăng:** HR tăng do kích hoạt hệ thần kinh giao cảm (SNS - Sympathetic Nervous System) [6]. RR giảm (tức là khoảng thời gian giữa hai nhịp

tim ngắn lại). HRV (Heart Rate Variability - Biến thiên nhịp tim) giảm, phản ánh mức độ căng thẳng cao hơn [7].

- **Khi thư giãn hoặc tải nhận thức giảm:** HR giảm, RR tăng (khoảng giữa các nhịp tim dài hơn). HRV cao hơn, phản ánh sự hoạt động mạnh của hệ thần kinh đối giao cảm (*PNS - Parasympathetic Nervous System*) [7].

Các nghiên cứu đã chứng minh rằng sự thay đổi HR và RR là dấu hiệu đáng tin cậy để phát hiện tải nhận thức trong các nhiệm vụ nhận thức phức tạp [4].

1.2.2. Độ dẫn điện da (GSR - Galvanic Skin Response)

Phản ứng điện da (GSR) đo lường sự thay đổi trong độ dẫn điện của da do hoạt động của tuyến mồ hôi. Vì tuyến mồ hôi chỉ chịu sự kiểm soát của hệ thần kinh giao cảm, GSR là một chỉ số trực tiếp phản ánh mức độ kích thích thần kinh và căng thẳng nhận thức [8].

- **GSR tăng khi tải nhận thức cao** do tuyến mồ hôi tiết nhiều hơn, làm tăng độ dẫn điện của da [4].
- **GSR giảm khi thư giãn**, phản ánh mức độ hoạt động thấp hơn của hệ thần kinh giao cảm.

GSR bao gồm hai thành phần chính:

- **Phasic Component (SCR - Skin Conductance Response):** thay đổi nhanh theo các kích thích ngắn hạn.
- **Tonic Component (SCL - Skin Conductance Level):** thay đổi chậm theo mức độ căng thẳng chung [8].

1.2.3. Nhiệt độ da (Temp - Skin Temperature)

Nhiệt độ da (*Temp*) phản ánh sự điều hòa nhiệt của cơ thể và hoạt động của hệ thần kinh tự động [5].

- **Khi tải nhận thức cao:** SNS kích hoạt gây co mạch ngoại vi, làm nhiệt độ da giảm [4]. Đây là phản ứng bảo vệ, giúp cơ thể tập trung năng lượng cho não và cơ bắp.
- **Khi thư giãn hoặc hồi phục sau stress:** Hệ thần kinh đối giao cảm (PNS) chiếm ưu thế, mạch máu giãn ra, nhiệt độ da tăng trở lại.

Tuy nhiên, nhiệt độ da có độ trễ dài hơn so với HR và GSR, nên nó phù hợp để đo căng thẳng kéo dài hơn là phản ứng ngắn hạn [7].

1.2.4. Mối quan hệ giữa các tín hiệu sinh lý trong tải nhận thức

Các tín hiệu HR, RR, GSR và Temp không hoạt động riêng lẻ mà có mối liên hệ chặt chẽ với nhau trong phản ứng với tải nhận thức [4].

Bảng 1. 1 Mối quan hệ giữa các tín hiệu

Tín hiệu	Khi tải nhận thức cao	Khi thư giãn
HR (Nhịp tim)	Tăng	Giảm
RR (Khoảng R-R)	Giảm (tim đập nhanh hơn)	Tăng (tim đập chậm hơn)
GSR (Độ dẫn điện da)	Tăng (tuyến mồ hôi hoạt động mạnh)	Giảm
Temp (Nhiệt độ da)	Giảm (do co mạch)	Tăng (do giãn mạch)

Bằng cách kết hợp nhiều tín hiệu sinh lý, chúng ta có thể phân tích chính xác hơn mức độ tải nhận thức của một cá nhân theo thời gian thực.

HR, RR, GSR và Temp là những tín hiệu quan trọng giúp đánh giá tải nhận thức. Mỗi tín hiệu phản ánh một khía cạnh khác nhau của hệ thần kinh tự động, từ đó cho phép nhận diện trạng thái căng thẳng, tập trung hoặc thư giãn của con người. Việc phân tích những tín hiệu này đóng vai trò quan trọng trong các ứng dụng như giám sát sức khỏe, tối ưu hóa hiệu suất làm việc và thiết kế giao diện người dùng thông minh.

1.3. Mạng Bayesian (Bayesian Network - BN)

Trong nhiều lĩnh vực nghiên cứu và ứng dụng thực tế, việc xử lý dữ liệu không chắc chắn và đưa ra quyết định dựa trên thông tin có giới hạn là một thách thức lớn. Mạng Bayesian (Bayesian Network - BN) là một công cụ mạnh mẽ giúp mô hình hóa các mối quan hệ xác suất giữa các biến và thực hiện suy luận dựa trên dữ liệu [11]. Với khả năng biểu diễn sự phụ thuộc nhân quả và cập nhật tri thức khi có thông tin mới, mạng Bayesian đã trở thành một phương pháp quan trọng trong trí tuệ nhân tạo [12], khoa học dữ liệu, y học [13], tài chính, và nhiều lĩnh vực khác.

Phần dưới đây sẽ trình bày khái niệm, cấu trúc, lợi ích cũng như các ứng dụng thực tiễn của mạng Bayesian, giúp hiểu rõ hơn về vai trò và tiềm năng của phương pháp này trong phân tích và ra quyết định.

1.3.1. Định nghĩa mạng Bayesian

Mạng Bayesian (Bayesian Network - BN) là một mô hình đồ thị xác suất đại diện cho tập hợp các biến ngẫu nhiên và mối quan hệ phụ thuộc có điều kiện giữa chúng. Mạng này được biểu diễn bằng một đồ thị có hướng không chu trình, trong đó các nút biểu diễn các biến và các cạnh có hướng thể hiện quan hệ nhân quả hoặc phụ thuộc xác suất giữa các biến đó. Mỗi biến trong mạng có một bảng xác suất có điều kiện (CPT - Conditional Probability Table) mô tả phân bố xác suất dựa trên các biến cha của nó. Công thức tổng quát của phân phối xác suất chung trong một mạng Bayesian:

$$P(X_1, X_2, \dots, X_n) = \prod_{i=1}^n P(X_i | Pa(X_i))$$

Trong đó, $Pa(X_i)$ là tập hợp các biến cha của X_i trong đồ thị DAG.


1.3.2. Cấu trúc của mạng Bayesian

Có hai thành phần liên quan đến việc học một mạng Bayes: (i) học cấu trúc (structure learning), bao gồm việc xác định một DAG mô tả tốt nhất các mối quan hệ nhân quả giữa các nút trong mạng và (ii) học tham số (parameter learning), bao gồm việc tìm hiểu về các phân phối xác suất có điều kiện dựa vào dữ liệu của từng biến [10]. Định lý Bayes mô tả phân phối xác suất có điều kiện như sau:

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

Một mạng Bayesian bao gồm ba thành phần chính:

- ❖ **Tập hợp các biến (Nút - Nodes):** Biến có thể là rời rạc (ví dụ: "Có bệnh" hoặc "Không có bệnh") hoặc liên tục (ví dụ: mức độ huyết áp).
- ❖ **Tập hợp các quan hệ phụ thuộc (Cạnh có hướng - Directed Edges):** Các cạnh có hướng từ biến cha đến biến con, thể hiện mối quan hệ nhân quả hoặc phụ thuộc xác suất.
- ❖ **Bảng xác suất có điều kiện (CPT - Conditional Probability Table):** Mỗi biến có một bảng xác suất có điều kiện dựa trên các biến cha của nó. Nếu một biến không có cha, nó sẽ có phân phối xác suất tiên nghiệm (prior probability).



Hình 1. 5: Mạng Bayesian giả định để mô hình hóa nguy cơ mắc chứng mất trí nhớ.[14]

Mạng Bayesian trong Hình 1.5 được thiết kế để mô hình hóa nguy cơ mắc chứng mất trí nhớ (Dementia - D) dựa trên nhiều yếu tố sức khỏe và nhân khẩu học. Nó bao gồm các biến nhị phân (có/không), được biểu diễn dưới dạng nút (nodes) trong đồ thị có hướng không chu trình (DAG - Directed Acyclic Graph), với các cạnh có hướng thể hiện quan hệ nhân quả hoặc phụ thuộc xác suất giữa các biến [14].

Các biến trong mạng Bayesian:

- Age (A) – Tuổi tác: a (≥ 65 tuổi); $\neg a$ (< 65 tuổi). Ảnh hưởng: Tuổi tác là yếu tố nguy cơ chính của nhiều bệnh lý thần kinh. Người cao tuổi có nguy cơ cao bị Neuronal Atrophy (N) và Stroke (S).
- Neuronal Atrophy (N) – Teo tế bào thần kinh: n (có teo tế bào thần kinh); $\neg n$ (không có teo tế bào thần kinh). Ảnh hưởng: Teo tế bào thần kinh làm suy giảm chức năng nhận thức, ảnh hưởng trực tiếp đến khả năng mắc Dementia (D).

- Stroke (S) – Đột quy: s (có tiền sử đột quy); $\neg s$ (không có tiền sử đột quy). Ảnh hưởng: Đột quy có thể gây tổn thương não nghiêm trọng, làm tăng nguy cơ mắc Dementia (D) và gây Paralysis (P).
- Paralysis (P) – Bị liệt: p (có liệt); $\neg p$ (không bị liệt). Ảnh hưởng: Bị liệt thường là hệ quả của đột quy nghiêm trọng.
- Dementia (D) – Mất trí nhớ: d (bị mất trí nhớ); $\neg d$ (không bị mất trí nhớ). Ảnh hưởng: Bệnh này là kết quả của các yếu tố N (Teo tế bào thần kinh) và S (Đột quy).

Mạng Bayesian này có các mối quan hệ nhân quả sau:

- Tuổi tác (A) ảnh hưởng đến đột quy (S) và teo tế bào thần kinh (N): Người cao tuổi (a) có nguy cơ cao bị đột quy (s) hoặc teo tế bào thần kinh (n).
- Đột quy (S) ảnh hưởng đến liệt (P) và mất trí nhớ (D): Nếu một người bị đột quy (s), họ có nguy cơ cao bị liệt (p); Đột quy cũng làm tăng nguy cơ mất trí nhớ (d).
- Teo tế bào thần kinh (N) làm tăng nguy cơ mất trí nhớ (D): Nếu một người bị teo tế bào thần kinh (n), họ có nguy cơ cao bị mất trí nhớ (d).

Bảng xác suất cho các biến và các điều kiện khác nhau được đưa ra bên cạnh các biến tương ứng:


- $p(A)$: Xác suất tuổi của bệnh nhân.
- $p(N|A)$: Xác suất teo tế bào thần kinh dựa trên tuổi.
- $p(S|A)$: Xác suất đột quy dựa trên tuổi.
- $p(D|N,S)$: Xác suất mắc chứng mất trí nhớ dựa trên teo tế bào thần kinh và đột quy.
- $p(P|S)$: Xác suất bị liệt dựa trên đột quy.

Từ các mối quan hệ nhân quả và bảng xác suất, diễn giả mô hình có thể như sau:

- Nếu một người ≥ 65 tuổi (a), họ có 50% khả năng bị teo tế bào thần kinh (n) và 30% khả năng bị đột quy (s).

- Nếu một người bị đột quỵ (s), họ có 75% khả năng bị liệt (p).
- Nếu một người bị cả teo tế bào thần kinh (n) và đột quỵ (s), xác suất mắc mất trí nhớ (d) lên đến 96%.
- Nếu một người không có teo tế bào thần kinh ($\neg n$) và không bị đột quỵ ($\neg s$), xác suất mắc mất trí nhớ chỉ 10%.

1.3.3. Lợi ích và ứng dụng của mạng Bayesian



Hình 1. 6: Sơ đồ mô tả các ứng dụng của Mạng Bayesian. (Nguồn Internet)


Mạng Bayesian không chỉ là công cụ mạnh mẽ trong việc mô hình hóa các mối quan hệ nhân quả giữa các biến mà còn đóng vai trò thiết yếu trong nhiều chức năng phân tích dữ liệu hiện đại. Trước hết, nó hỗ trợ quá trình suy luận xác suất (probabilistic inference), cho phép hệ thống đưa ra quyết định dựa trên xác suất ngay cả trong những tình huống dữ liệu bị thiếu, không đầy đủ hoặc có nhiễu, điều rất thường gặp trong dữ liệu sinh lý thực tế. Bên cạnh đó, mạng Bayesian còn đóng vai trò như một công cụ hỗ trợ chẩn đoán và ra quyết định hiệu quả trong nhiều lĩnh vực như y tế, tài chính, và các hệ thống thông minh, nơi yêu cầu phân tích dữ liệu phức tạp để đưa ra lựa chọn chính xác. Cuối cùng, đây cũng là một mô hình lý tưởng cho bài toán dự đoán (predictive modeling), khi có thể tận dụng dữ liệu lịch sử cùng với mối quan hệ xác

suất giữa các biến để dự đoán xu hướng, hành vi hoặc sự kiện trong tương lai một cách hợp lý và có thể giải thích được. Những đặc tính này khiến mạng Bayesian trở thành một lựa chọn đặc biệt phù hợp cho các hệ thống giám sát và điều chỉnh tải nhận thức theo thời gian thực trong môi trường động và đa yếu tố. Mạng Bayesian có nhiều ứng dụng thực tiễn trong các lĩnh vực khác nhau, đặc biệt là trong trí tuệ nhân tạo và học máy. Trong lĩnh vực y tế, chúng được sử dụng để hỗ trợ chẩn đoán và ra quyết định lâm sàng bằng cách mô hình hóa mối quan hệ giữa các triệu chứng, bệnh lý và phương pháp điều trị, giúp cải thiện độ chính xác và hiệu quả của các hệ thống hỗ trợ bác sĩ [15].

Trong tài chính và bảo hiểm, mạng Bayesian giúp đánh giá rủi ro và phát hiện gian lận bằng cách phân tích dữ liệu lịch sử và nhận diện các mẫu bất thường. Điều này giúp các tổ chức tài chính giảm thiểu tổn thất và nâng cao độ tin cậy của hệ thống quản lý rủi ro [16]. *Trong lĩnh vực an ninh mạng*, chúng được áp dụng để phát hiện xâm nhập và tấn công mạng bằng cách xác định các hành vi bất thường trong luồng dữ liệu, từ đó đưa ra cảnh báo sớm và giúp bảo vệ hệ thống trước các mối đe dọa [17]. Ngoài ra, mạng Bayesian còn có ứng dụng trong xe tự lái, giúp hệ thống đưa ra quyết định trong môi trường phức tạp bằng cách mô hình hóa tương tác giữa phương tiện, người đi bộ và các yếu tố giao thông khác [18]. Bên cạnh đó, trong xử lý ngôn ngữ tự nhiên, mạng Bayesian được sử dụng để cải thiện độ chính xác của dịch máy, chatbot và phân tích ngữ nghĩa thông qua mô hình xác suất của từ và câu [19].

1.4. Lựa chọn đặc trưng và Sequential Backward Selection (SBS)

Trong các bài toán học máy và xử lý dữ liệu sinh lý, việc lựa chọn đặc trưng đóng vai trò quan trọng để tối ưu hóa hiệu suất của mô hình và giảm bớt sự dư thừa của dữ liệu. Một trong những phương pháp phổ biến được sử dụng để chọn ra tập hợp đặc trưng tối ưu là SBS.




Hình 1. 7: Thuật toán giảm đặc trưng lùi dần (SBS)

Phương pháp đề xuất để lựa chọn đặc trưng và huấn luyện mô hình được thực hiện thông qua quy trình SBS, với các bước cụ thể được thể hiện như hình 1.7 như sau:

Đầu tiên, ta bắt đầu với tập đặc trưng gốc gồm 106 đặc trưng. Mục tiêu chính là rút gọn dần số lượng đặc trưng bằng cách đánh giá độ chính xác (accuracy) của mô hình sau mỗi lần loại bỏ. Ở vòng lặp đầu tiên, chúng ta sinh ra tất cả các tập con bằng cách lần lượt bỏ đi từng đặc trưng một, tạo thành 105 tập con, mỗi tập có 105 đặc trưng. Sau đó, ta huấn luyện mô hình trên từng tập con này và ghi nhận độ chính xác đạt được. Sau khi đánh giá xong, ta sẽ chọn ra tập con có độ chính xác cao nhất. Đặc trưng nào không xuất hiện trong tập con tốt nhất đó sẽ được coi là ít quan trọng nhất và bị loại bỏ khỏi tập gốc, giảm số lượng đặc trưng từ 106 xuống còn 105. Tiếp theo, quy trình này được lặp lại: từ tập 105 đặc trưng, ta tiếp tục tạo các tập con mới (gồm 104 đặc trưng), huấn luyện mô hình trên mỗi tập con, chọn tập con có accuracy cao nhất, loại bỏ thêm một đặc trưng ít quan trọng nhất. Quy trình lặp lại liên tục như vậy mỗi vòng lặp sẽ loại đi một đặc trưng cho đến khi chỉ còn lại một đặc trưng duy nhất. Kết quả cuối cùng là thu được một tập đặc trưng tối ưu giúp mô hình đạt độ chính xác cao nhất.

CHƯƠNG 2: CÁC CÔNG TRÌNH NGHIÊN CỨU LIÊN QUAN

2.1 Những vấn đề liên quan đến tải nhận thức



Hình 2. 1: Các tín hiệu ảnh hưởng tới các yếu tố xung quanh

Việc đo lường tải nhận thức (Cognitive Load - CL) là một thách thức lớn trong lĩnh vực tương tác người – máy và khoa học nhận thức. CL là một trạng thái tâm lý ẩn, phản ánh mức độ tài nguyên nhận thức mà một cá nhân sử dụng để thực hiện một nhiệm vụ cụ thể. Do bản chất ẩn của nó, tải nhận thức không thể được đo lường trực tiếp, mà chỉ có thể được suy luận gián tiếp thông qua các tín hiệu sinh lý hoặc hành vi bên ngoài. Các tín hiệu sinh lý thường được sử dụng bao gồm: nhịp tim, điện dẫn da, nhiệt độ da và nhịp thở. Đây là các chỉ số phản ánh hoạt động của hệ thần kinh tự chủ, vốn có liên hệ với trạng thái tâm lý và căng thẳng tinh thần của con người. Bên cạnh đó, các chỉ số hành vi như ánh mắt, cử động chuột, thời gian phản hồi... được sử dụng để hỗ trợ cho việc suy luận CL [20]. Tuy nhiên, việc sử dụng các tín hiệu


này để đánh giá CL vẫn tồn tại nhiều hạn chế. Trước tiên, các tín hiệu sinh lý dễ bị ảnh hưởng bởi các yếu tố bên ngoài như nhiệt độ môi trường, chuyển động vật lý, cảm xúc cá nhân hoặc thậm chí sự nhiễu điện tử từ thiết bị đo [21]. Hơn nữa, các tín hiệu này thường không ổn định, biến động theo thời gian và phụ thuộc vào từng cá nhân cụ thể, gây khó khăn trong việc xây dựng mô hình phân loại tổng quát. Đặc biệt, mối quan hệ giữa tín hiệu sinh lý và tải nhận thức không phải luôn tuyến tính hoặc rõ ràng, mà có thể mang tính phi tuyến, đa chiều và tương tác phức tạp [22]. Do đó, việc xây dựng các mô hình phân tích mạnh mẽ, có khả năng trích xuất các đặc trưng phù hợp và học được mối quan hệ phức tạp giữa tín hiệu đầu vào và trạng thái nhận thức trở thành một nhu cầu cấp thiết. Đây là lý do tại sao nhiều nghiên cứu hiện nay tập trung vào việc kết hợp nhiều loại tín hiệu, sử dụng các phương pháp học máy hoặc học sâu, và áp dụng chiến lược xử lý tín hiệu tiên tiến để nâng cao độ chính xác trong đánh giá tải nhận thức.

Bên cạnh đó, mạng Bayesian (Bayesian Networks - BNs) đã được sử dụng trong một số nghiên cứu để mô hình hóa mối quan hệ nhân quả giữa tải nhận thức và các yếu tố sinh lý. Một nghiên cứu điển hình đã áp dụng BNs để đánh giá ảnh hưởng của điều kiện làm việc đối với tai nạn lao động, trong đó mạng Bayesian được sử dụng để phân tích mối liên hệ giữa triệu chứng thể chất, tâm lý và nguy cơ tai nạn [25].

2.2. Phương pháp đánh giá tải nhận thức truyền thống

NASA-TLX (Task Load Index) là một công cụ phổ biến và mạnh mẽ trong việc đánh giá tải nhận thức và khối lượng công việc của người vận hành trong quá trình thực hiện các nhiệm vụ. Đây là một thang đo đa chiều, được thiết kế để ước tính mức độ khối lượng công việc của người sử dụng hoặc nhóm người thực hiện nhiệm vụ. NASA-TLX giúp đo lường cảm nhận của người tham gia về các yếu tố như độ khó, thời gian, sự căng thẳng và khối lượng công việc tinh thần, từ đó tạo điều kiện để cải thiện hiệu suất công việc và tối ưu hóa thiết kế hệ thống. Đặc biệt, thang đo này giúp

cung cấp cái nhìn về các yếu tố tác động đến hiệu suất và sự căng thẳng của người tham gia.[23]



Hình 2. 2: Câu hỏi thang đo NASA-TLX gồm 6 yếu tố thành phần dùng để đánh giá tải nhận thức [1]


Dựa vào hình 1, NASA-TLX là một công cụ đánh giá tải nhận thức đa chiều, bao gồm 6 yếu tố chính, mỗi yếu tố được người tham gia đánh giá trên thang điểm từ rất thấp đến rất cao. Trong đó:

- Nhu cầu tinh thần (MD): Cần có bao nhiêu hoạt động tinh thần và tri giác (ví dụ: suy nghĩ, quyết định, tính toán, ghi nhớ, nhìn, tìm kiếm, ...). Nhiệm vụ có dễ dàng hay đòi hỏi, đơn giản hay phức tạp, chính xác hay dễ bỏ qua sai sót?
- Nhu cầu thể chất (PD): Cần bao nhiêu hoạt động thể chất (ví dụ: đẩy, kéo, xoay, kiểm soát, kích hoạt, ...). Nhiệm vụ có nhẹ nhàng hay nặng nhọc, chậm rãi hay đòi hỏi tốc độ, thoải mái hay mệt mỏi?
- Nhu cầu thời gian (TD): Bạn cảm thấy áp lực thời gian ở mức độ nào do tốc độ hoặc tính cấp bách của nhiệm vụ? Tốc độ có chậm rãi và thư thái hay nhanh chóng và căng thẳng?
- Hiệu suất (PE): Bạn nghĩ mình đã thành công như thế nào trong việc hoàn thành mục tiêu của nhiệm vụ? Bạn hài lòng ở mức độ nào với hiệu suất của bản thân?

- Nỗ lực (EF): Bạn đã phải làm việc chăm chỉ như thế nào (cả về mặt tinh thần lẫn thể chất) để đạt được mức hiệu suất như mong muốn?
- Thất vọng (Frustration - FR): Mức độ bạn cảm thấy bất an, chán nản, cáu kỉnh, căng thẳng và khó chịu trong quá trình thực hiện nhiệm vụ? Hay bạn cảm thấy thoải mái, hài lòng và thư thái?

Mỗi thang đo con được đo bằng một mục duy nhất. Do đó, toàn bộ công cụ này bao gồm sáu mục. Các điểm đầu cuối của các mục thường là thấp và cao, ngoại trừ thang đo hiệu suất, với hai điểm đầu cuối là tốt và kém. Số lượng mục ít khiến công cụ này dễ sử dụng và triển khai. Đồng thời, các thang đo con có thể được báo cáo riêng biệt bên cạnh giá trị tổng hợp TLX, từ đó giúp tăng cường khả năng chẩn đoán của công cụ [24].


2.3 Phương pháp đánh giá tải nhận thức bằng máy học



Hình 2. 3: Phương pháp đề xuất của Borisov với mô hình máy học. [25]

Một trong những hướng tiếp cận nổi bật trong việc phát hiện tải nhận thức là sử dụng dữ liệu sinh lý học thu thập từ thiết bị đeo tay kết hợp với các mô hình học máy. Borisov và cộng sự đã đề xuất một phương pháp phát hiện tải nhận thức dựa trên các tín hiệu sinh lý như điện dẫn da, nhịp tim, tần số hô hấp, nhiệt độ da được thu thập từ thiết bị đeo tay [25]. Dữ liệu được thu thập trong khoảng thời gian 30 giây, sau đó được chuyển đổi từ dạng chuỗi thời gian sang các đặc trưng tĩnh bằng cách trích xuất các thống kê đặc trưng. Với hướng tiếp cận như sau: chuyển đổi dữ liệu thô thành các

đặc trưng phân biệt có độ chiều thấp hơn và huấn luyện một mô hình ensemble gồm 8 mô hình con sử dụng thuật toán GBDT. Các mô hình con được huấn luyện với các siêu tham số khác nhau được tối ưu bằng random search và tham số bayes, nhằm tăng độ đa dạng. Cuối cùng, kết quả đầu ra được tính trung bình từ dự đoán của các mô hình con. Mô hình được đánh giá bằng chiến lược cross-validation kết quả cao nhất trong cuộc thi CogLoad@UbiComp 2020. Ngoài ra, tác giả còn sử dụng các kỹ thuật giải thích mô hình như SHAP và CancelOut để đánh giá tầm quan trọng của các đặc trưng. Phân tích này cho thấy độ lệch chuẩn của tín hiệu HR và RR là các đặc trưng có giá trị phân biệt cao nhất cho mô hình. Bên cạnh đó, công trình này cũng nhấn mạnh tầm quan trọng của việc xử lý đặc trưng hiệu quả hơn là áp dụng các mô hình học sâu phức tạp khi dữ liệu còn hạn chế về kích thước và độ đa dạng.



Hình 2. 4: Phương pháp đề xuất của Jaiswal với mô hình máy học. [26]

Một hướng tiếp cận đáng chú ý khác đến từ Jaiswal và cộng sự (2021), khi nhóm tác giả đề xuất một phương pháp đánh giá tải nhận thức trong bối cảnh thực tế dựa trên các tín hiệu sinh lý thu thập từ thiết bị đeo tay [26]. Công trình sử dụng tập dữ liệu CogLoad, bao gồm các tín hiệu GSR, HR, RR và nhiệt độ da, được ghi nhận từ thiết

bị Microsoft Band 2 trong quá trình người tham gia thực hiện các bài kiểm tra nhận thức với độ khó khác nhau. Sau khi chia nhỏ dữ liệu thành các cửa sổ 30 giây, nhóm nghiên cứu đã tiến hành trích xuất đặc trưng theo cả miền thời gian và miền tần số, sử dụng công cụ FDP do chính nhóm phát triển để sinh ra hơn 1.500 đặc trưng tổng quát. Sau đó, họ sử dụng các thuật toán lựa chọn đặc trưng để rút gọn còn 50 đặc trưng tối ưu nhất. Để tăng cường dữ liệu huấn luyện và cải thiện tính khái quát, kỹ thuật SMOTE được áp dụng nhằm tạo thêm các mẫu dữ liệu tổng hợp có tính chất tương đồng với dữ liệu thực.

Cuối cùng, mô hình RF với 750 cây được huấn luyện và đánh giá theo nhiều kịch bản khác nhau. Phương pháp này đạt độ chính xác 69% trên dữ liệu chưa từng thấy, cho thấy tính ổn định và hiệu quả vượt trội so với các công trình trước đó sử dụng cùng tập dữ liệu. Không chỉ dừng lại ở mặt kỹ thuật, công trình này còn hướng đến tính ứng dụng thực tế cao, cho thấy khả năng triển khai trong các hệ thống theo dõi tải nhận thức theo thời gian thực trong môi trường.

2.4 Thách thức nghiên cứu

Mặc dù các phương pháp đánh giá tải nhận thức hiện nay đã có nhiều tiến bộ đáng kể, mỗi phương pháp đều tồn tại những hạn chế nhất định, đặc biệt khi áp dụng trong môi trường thực tế và yêu cầu đánh giá theo thời gian thực.

Phương pháp truyền thống như NASA-TLX mang lại cái nhìn định tính và đa chiều về trạng thái nhận thức của người dùng thông qua các yếu tố như nỗ lực, áp lực thời gian, hay sự thất vọng. Tuy nhiên, phương pháp này phụ thuộc hoàn toàn vào đánh giá chủ quan của người tham gia, dễ bị ảnh hưởng bởi cảm xúc, kinh nghiệm cá nhân và không thể sử dụng cho các tình huống đòi hỏi đánh giá liên tục và khách quan. Đồng thời, việc thu thập thông tin chỉ thực hiện sau khi hoàn thành nhiệm vụ, khiến công cụ này không phù hợp với các hệ thống cần tương tác theo thời gian thực. Trong

khi đó, các phương pháp hiện đại dựa trên máy học và dữ liệu sinh lý học như tín hiệu GSR, HR, RR, TEMP lại cho phép đánh giá khách quan và liên tục, nhờ khả năng trích xuất đặc trưng và huấn luyện mô hình phân loại. Tuy nhiên, những tín hiệu sinh lý này thường không ổn định, dễ bị nhiễu bởi các yếu tố môi trường như nhiệt độ, chuyển động, hoặc trạng thái cảm xúc. Bên cạnh đó, mối quan hệ giữa tín hiệu sinh lý và tải nhận thức không mang tính tuyến tính rõ ràng, mà thường phi tuyến, đa chiều và phức tạp. Một thách thức lớn khác là hầu hết các mô hình học máy hiện tại (như GBĐT hay RF) hoạt động theo cơ chế “hộp đen”, khó diễn giải nguyên nhân cụ thể dẫn đến tải nhận thức cao. Điều này gây khó khăn trong việc xây dựng hệ thống phản hồi và điều chỉnh tương tác người–máy phù hợp.


Trước những thách thức đó, nghiên cứu này đề xuất sử dụng mạng Bayesian như một mô hình có tiềm năng giải quyết các vấn đề nêu trên. Mạng Bayesian cho phép mô hình hóa các mối quan hệ nhân quả và điều kiện xác suất giữa các tín hiệu sinh lý và trạng thái nhận thức. Khác với mô hình “hộp đen”, BN có khả năng diễn giải rõ ràng mối quan hệ giữa các biến đầu vào và kết quả đầu ra, từ đó cung cấp thông tin hữu ích cho các hệ thống phản hồi thích ứng. Ví dụ, mô hình có thể mô tả mối quan hệ: “Tải nhận thức tăng cao khi HR tăng và GSR có biến động lớn”, với xác suất cụ thể. Ngoài ra, BN cũng cho phép tích hợp cả tri thức chuyên gia lẫn dữ liệu thực nghiệm, và xử lý tốt dữ liệu thiếu hoặc bị nhiễu. Trong nghiên cứu này, mạng Bayesian được đề xuất như một công cụ giải thích và suy luận mối quan hệ giữa các tín hiệu sinh lý như HR, RR, GSR, TEMP và trạng thái tải nhận thức. Đây là bước tiến quan trọng hướng đến việc xây dựng mô hình nhận thức có khả năng diễn giải, đáng tin cậy và ứng dụng tốt trong môi trường thực tế như dạy học thông minh, chăm sóc sức khỏe, hay hỗ trợ công việc có cường độ cao.

CHƯƠNG 3: TẬP DỮ LIỆU VÀ PHƯƠNG PHÁP ĐỀ XUẤT

3.1. Tổng quan tập dữ liệu

Phương pháp được đề xuất trong nghiên cứu này dựa trên tập dữ liệu CogLoad [1], được công bố tại hội nghị UbiComp 2020. Tập dữ liệu nghiên cứu bao gồm 825 mẫu từ 23 người tham gia, trong đó các trường hợp nghỉ ngơi được gán nhãn "không tải" (Rest), còn các trường hợp thực hiện nhiệm vụ được gán nhãn "tải nhận thức" (Task). Mỗi phiên bản dữ liệu chứa 30 giây tín hiệu từ bốn nguồn: RR, GSR, ST, HR.


Dữ liệu được chia thành hai tập: tập huấn luyện gồm 632 mẫu từ 18 đối tượng và tập kiểm tra gồm 193 mẫu từ 5 đối tượng. Biểu đồ tròn hình 3.1 trực quan hóa sự phân bố nhãn trong hai tập dữ liệu, cho thấy sự cân bằng tương đối: tập huấn luyện có 50.2% mẫu Rest và 49.8% mẫu Task, trong khi tập kiểm tra có 49.2% mẫu Rest và 50.8% mẫu Task.



Hình 3. 1: Mô tả tập huấn luyện và kiểm tra trong tập dữ liệu


Mặc dù NASA-TLX là một công cụ đánh giá nhận thức công việc và không liên quan trực tiếp đến hoạt động thể chất, nhưng quá trình trả lời các câu hỏi về mức độ căng thẳng, mệt mỏi hay hiệu suất có thể khiến người tham gia hồi tưởng lại những áp lực đã trải qua. Điều này có thể dẫn đến những thay đổi sinh lý, chẳng hạn như nhịp thở tăng lên. Biểu đồ đường (Hình 3.2) của đối tượng iz3x1 cho thấy dao động nhịp thở

trong thí nghiệm nằm trong khoảng 0.16 – 1.14 giây. Nhịp thở cơ bản thường dao động từ 0.6 đến 1 giây hoặc nhanh hơn một chút, nhưng những giá trị dưới 0.5 giây có thể được xem là nhiễu. Do đó, dữ liệu ban đầu có thể chứa nhiều biến động và xu hướng phức tạp, đòi hỏi một quá trình phân tích kỹ lưỡng để xác định các thông tin quan trọng.



Hình 3. 2: Dữ liệu cảm biến của một đối tượng đối với tín hiệu RR.


Khi sử dụng một cửa sổ thời gian quá dài để phân tích, các đỉnh tín hiệu hoặc sự thay đổi đột ngột có thể bị làm phẳng, dẫn đến mất thông tin quan trọng. Để khắc phục điều này, ta chỉ tập trung vào 30 giây cuối cùng của mỗi nhiệm vụ nhằm bảo tồn các đỉnh tín hiệu. Cách tiếp cận này giúp giữ nguyên sự hiện diện của các biến động quan trọng, làm nổi bật những thay đổi đột ngột trong dữ liệu và đảm bảo rằng các đặc điểm quan trọng không bị mất trong quá trình xử lý.



Hình 3. 3: Dữ liệu sau khi trích xuất phân đoạn 30 giây của một đối tượng.


Sau khi trích xuất 30 giây cuối cùng của mỗi nhiệm vụ được trực quan hóa hình 3.3, ta tiến hành phân tích tín hiệu RR để bảo tồn các đặc điểm quan trọng như các đỉnh và xu hướng thay đổi. Biểu đồ trên thể hiện tần số hô hấp theo từng phân đoạn thời gian trong nhiệm vụ của người dùng có `user_id`: 6frz4, với hai mức độ khác nhau. Biểu đồ bên trái thể hiện dữ liệu ở level 2, trong khi biểu đồ bên phải tương ứng với level 0. Ở level 2, RR có xu hướng tăng lên, đạt đỉnh khoảng giữa nhiệm vụ, sau đó giảm dần về cuối. Xu hướng này có thể phản ánh sự thay đổi trạng thái sinh lý khi thực hiện nhiệm vụ khó, với sự gia tăng rồi giảm dần của RR. Ngược lại, ở level 0, tần số hô hấp dao động nhiều nhưng không có xu hướng tăng giảm rõ ràng như ở level 2, cho thấy trạng thái ổn định hơn khi thực hiện nhiệm vụ đơn giản.

Tiếp tục sử dụng các phương pháp trực quan hóa khác để hiểu rõ hơn về sự phân bố của các thông số sinh lý. Một trong những cách hiệu quả để phân tích sự khác biệt giữa các trạng thái là sử dụng biểu đồ violin. Biểu đồ này giúp thể hiện rõ sự phân bố của các giá trị theo từng mức độ nhiệm vụ, đồng thời cung cấp thông tin về độ tập trung và sự biến thiên của dữ liệu. Hình 3.4 minh họa sự thay đổi của bốn tín hiệu sinh lý trong các trạng thái nghỉ (rest) và các mức độ làm nhiệm vụ (level 0, level 1, level 2).




Hình 3. 4: Biểu đồ violin so sánh sự phân bố giữa các mức độ nhiệm vụ.

Tập dữ liệu bao gồm tổng cộng 825 mẫu, trong đó trạng thái nghỉ ngơi (Rest - Không tải) có 412 mẫu, chiếm 49.9%, còn trạng thái nhiệm vụ (Task - Tải nhận thức) có 413 mẫu, chiếm 50.1% được trực quan hóa ở hình 3.5. Sự phân bố gần như cân bằng giữa hai trạng thái giúp đảm bảo tính công bằng khi xây dựng mô hình học máy, hạn chế ảnh hưởng của vấn đề mất cân bằng dữ liệu, từ đó nâng cao độ chính xác và khả năng tổng quát hóa của mô hình. Bên cạnh đó, mỗi đối tượng trong tập dữ liệu được gán một mã định danh duy nhất, giúp theo dõi, phân tích dữ liệu một cách chính xác và hỗ trợ quá trình chia tách tập huấn luyện - kiểm tra theo từng đối tượng, đảm bảo tính khách quan trong đánh giá mô hình.



Hình 3. 5: Tỷ lệ của hai nhãn "Rest (0)" và "Task (1)" trong tập dữ liệu.

3.2. Phương pháp đề xuất



Hình 3. 6: Hướng tiếp cận trong nghiên cứu được đề xuất


Nghiên cứu này đề xuất một phương pháp ứng dụng mạng Bayesian để phân loại trạng thái nhận thức dựa trên tín hiệu sinh lý. Phương pháp tiếp cận được thiết kế nhằm tối ưu hóa quá trình tiền xử lý, trích xuất đặc trưng và xây dựng mô hình, giúp nâng cao độ chính xác trong việc nhận diện trạng thái nhận thức. Dựa trên hình 3.6, quy trình tiếp cận của chúng tôi bao gồm sáu bước chính nhằm tối ưu hóa quá trình tiền xử lý, trích xuất đặc trưng và xây dựng mô hình. Đầu tiên, dữ liệu thô từ các cảm biến sinh lý GSR, RR, HR và Temp được tiền xử lý bằng hai trường hợp: giữ nguyên dữ liệu gốc hoặc áp dụng trung bình trượt (window = 3 giây) để làm mượt tín hiệu. Tiếp theo, quá trình trích xuất đặc trưng được thực hiện, bao gồm đặc trưng thống kê cơ bản và đặc trưng chuyên gia được trích xuất bằng thư viện NeuroKit2. Sau đó, mô hình được huấn luyện bằng cách tham khảo các phương pháp từ cuộc thi UBIComp 2020, kết hợp với thuật toán SBS để lựa chọn tập đặc trưng tối ưu dựa trên hiệu suất cao nhất của mô hình. Tiếp theo, các đặc trưng được nhóm theo từng loại tín hiệu sinh lý nhằm đảm bảo thông tin nằm bắt được từ các tín hiệu. Từ đó xây dựng cấu trúc Mạng Bayesian và đánh giá tác động của từng nhóm bằng phương pháp vét cạn.

Cuối cùng, mô hình được đánh giá bằng Group K-Fold Cross-Validation, sử dụng các chỉ số như độ chính xác và ROC, đảm bảo hiệu suất cao và khả năng nhận diện chính xác trạng thái nhận thức.

3.2.1. Tiền xử lý dữ liệu

Dữ liệu sinh lý thô thường chứa nhiều nhiễu do sai số đo lường hoặc biến động tự nhiên của tín hiệu. Những tín hiệu nhiễu này có thể che khuất xu hướng chính, gây khó khăn cho quá trình phân tích và mô hình học máy. Để giảm thiểu tác động của nhiễu mà vẫn giữ được đặc trưng quan trọng của tín hiệu, dữ liệu được làm mượt bằng phương pháp trung bình trượt với cửa sổ có kích thước 3 (đường màu cam) hoặc 1 (đường màu xanh) được mô tả rõ hơn ở hình 3.7.

Bước làm mượt này giúp cải thiện tính ổn định của tín hiệu, tạo điều kiện thuận lợi cho việc trích xuất các đặc trưng thống kê và đặc trưng theo miền. Nhờ đó, mô hình học máy có thể nhận diện chính xác hơn sự khác biệt giữa các trạng thái sinh lý, nâng cao hiệu quả phân loại và dự đoán.



Hình 3. 7: Tín hiệu sau khi áp dụng trung bình trượt.

3.2.2. Trích xuất đặc trưng

Sau khi xác định phương pháp xử lý tín hiệu phù hợp, quá trình trích xuất đặc trưng sẽ được thực hiện nhằm chuyển đổi tín hiệu thành thông tin có ý nghĩa.


Bảng 3. 1: Các đặc trưng được sử dụng trong nghiên cứu.

Loại đặc trưng	Các đặc trưng
Thông kê cho mỗi tín hiệu (40 đặc trưng)	Trung bình (Mean), độ lệch chuẩn (Std), độ lệch (Skew), độ nhọn (Kurtosis), sai khác bậc một (Diff), sai khác bậc hai (Diff2), phân vị thứ 25 (Q25), phân vị thứ 75 (Q75), khoảng tứ phân vị (Qdev), phạm vi (Max-Min).
Đặc trưng chuyên gia tín hiệu RR (45 đặc trưng)	Thông kê thời gian (Time-domain HRV Features) •NN intervals: Mean (HRV_MeanNN), Median (HRV_MedianNN), IQR (HRV_IQRNN) •Biến thiên NN: SDNN (HRV_SDNN), RMSSD (HRV_RMSSD), SDSD (HRV_SDSD), MAD (HRV_MadNN) •Hệ số biến thiên: CVNN (HRV_CVNN), CVSD (HRV_CVSD), MCVNN (HRV_MCVNN) •Tỷ lệ NN: pNN50 (HRV_pNN50), pNN20 (HRV_pNN20) •Chỉ số HRV hình tam giác: HTI (HRV-HTI), TINN (HRV-TINN) Thông kê tần số (Frequency-domain HRV Features) •Dải tần cao: HF Power (HRV_HF), Normalized HF (HRV_HFn), LnHF (HRV_LnHF) Phân tích Poincaré (Poincaré Plot Features) •Trục chính: SD1 (HRV_SD1), SD2 (HRV_SD2), SD1/SD2 Ratio (HRV_SD1SD2) •Diện tích & chỉ số: S (HRV_S), CSI (HRV_CSI), CVI (HRV_CVI), CSI_Modified (HRV_CSI_Modified) Chỉ số động học & phức hợp (Nonlinear HRV Features) •Poincaré Index: PIP (HRV_PIP) •Chỉ số tự động & phân đoạn: IALS (HRV_IALS), PSS (HRV_PSS), PAS (HRV_PAS) •Chỉ số khác: GI (HRV_GI), SI (HRV_SI), AI (HRV_AI), PI (HRV-PI) Hệ số C & SD (Coefficient-based Features) •C & SD hệ số: C1d (HRV_C1d), C1a (HRV_C1a), SD1d

	(HRV_SD1d), SD1a (HRV_SD1a) •C2 & SD2 hệ số: C2d (HRV_C2d), C2a (HRV_C2a), SD2d (HRV_SD2d), SD2a (HRV_SD2a) •C & SD tổng quát: Cd (HRV_Cd), Ca (HRV_Ca), SDNNd (HRV_SDNNd), SDNNa (HRV_SDNNa) Entropy & Độ phức tạp •Entropy xấp xỉ: ApEn (HRV_ApEn)
Đặc trưng chuyên gia cho tín hiệu GSR (21 đặc trưng)	•SCR Onsets (Điểm khởi phát SCR): min, max, mean •SCR Peaks (Đỉnh SCR): min, max, mean •SCR Height (Độ cao SCR): min, max, mean •SCR Amplitude (Biên độ SCR): min, max, mean •SCR Rise Time (Thời gian tăng SCR): min, max, mean •SCR Recovery (Thời gian hồi phục SCR): min, max, mean •SCR Recovery Time (Thời gian phục hồi SCR): min, max, mean

Bảng 3.1 thể hiện các đặc trưng được trích xuất từ bốn tín hiệu sinh lý. Quá trình trích xuất được chia thành hai nhóm chính dưới đây:

- Đặc trưng thông kê cơ bản: Những đặc trưng này giúp mô tả tổng quát sự biến đổi của tín hiệu trong một khoảng thời gian nhất định, cung cấp nền tảng quan trọng cho các phương pháp phân tích chuyên sâu. Các chỉ số thống kê bao gồm như: Trung bình cộng (mean), độ lệch chuẩn (std), độ lệch (skewness), Độ nhọn (kurtosis), Đạo hàm bậc nhất (diff1) và bậc hai (diff2), Phân vị 25% (q25) và 75% (q75), độ lệch phân vị (qdev) và phạm vi tín hiệu (max-min).
- Đặc trưng chuyên gia: Trong nghiên cứu này, chúng tôi sử dụng thư viện NeuroKit2 để trích xuất các đặc trưng chuyên biệt từ tín hiệu sinh lý, bao gồm: Phản ứng điện da (GSR - Galvanic Skin Response) và sự thay đổi nhịp tim (HRV - Heart Rate Variability). NeuroKit2 cung cấp các công cụ mạnh mẽ để phân tích tín hiệu sinh lý một cách chính xác và hiệu quả. Những đặc trưng này đóng vai trò quan trọng trong việc ước tính tải trọng nhận thức, hỗ trợ giám sát trạng thái người dùng trong nhiều ứng dụng như theo dõi sức khỏe, phân tích hành vi và tối ưu hóa hiệu suất làm việc.



Hình 3. 8: Quy trình trích xuất đặc trưng của tín hiệu GSR


Phản ứng điện da (GSR - Galvanic Skin Response) là một chỉ số sinh lý quan trọng phản ánh mức độ căng thẳng và tải nhận thức của con người. Thông qua thư viện NeuroKit2, các đặc trưng quan trọng của tín hiệu GSR được trích xuất, bao gồm:

- SCR (Skin Conductance Response): Phát hiện các phản ứng điện da liên quan đến kích thích.
- Onsets, Peaks, Height, Amplitude: Đánh giá cường độ và biên độ phản ứng.
- Rise Time, Recovery, Recovery Time: Phân tích tốc độ xuất hiện và hồi phục của tín hiệu.

Dựa trên hình 3.8, quy trình xử lý tín hiệu GSR được thực hiện theo các bước sau: (i) Dữ liệu GSR ban đầu có tần số lấy mẫu 1 Hz được tái lấy mẫu thành 10 Hz nhằm tăng độ phân giải và cải thiện độ chính xác trong phân tích. (ii) Tín hiệu tái lấy mẫu được xử lý bằng thư viện NeuroKit2, giúp trích xuất các đặc trưng quan trọng liên quan đến phản ứng điện da. (iii) Từ các đặc trưng này, chúng tôi tính toán các giá trị thống kê gồm min, max, mean để tạo ra 21 đặc trưng.

Tần số hô hấp (RR - Respiration Rate) và biến thiên nhịp tim (HRV - Heart Rate Variability) là những chỉ số quan trọng trong việc phát hiện tải nhận thức. Đặc biệt, HRV, được tính toán dựa trên khoảng RR, đã được ứng dụng thành công trong nhiều nghiên cứu để đánh giá sự thay đổi sinh lý của cơ thể khi chịu tải nhận thức cao [9]. Sau khi tín hiệu RR được tiền xử lý và chuẩn hóa tần số, dữ liệu sẽ được xử lý bằng


NeuroKit2 nhằm trích xuất các đặc trưng HRV quan trọng, bao gồm như: SDNN, RMSSD, PNN50, LF/HF Ratio, ... giúp nhận diện tải nhận thức theo thời gian thực, từ đó hỗ trợ các hệ thống giám sát và tối ưu hóa hiệu suất làm việc của người dùng.



Hình 3. 9: Quy trình trích xuất đặc trưng của tín hiệu RR.

Quy trình xử lý tín hiệu RR (Hình 3.9) được thực hiện như sau: (i) Dữ liệu RR ban đầu có tần số 1 Hz tín hiệu được nội suy lên 1000 Hz để đảm bảo độ chính xác cao khi phân tích HRV. (ii) Dữ liệu RR được xử lý bằng NeuroKit2 để trích xuất các đặc trưng HRV quan trọng. (iii) Cuối cùng, tiến hành lọc đặc trưng, loại bỏ các đặc trưng chứa giá trị NaN và giữ lại 45 đặc trưng tốt nhất để làm giá trị đầu vào trong việc phân tích tải trọng nhận thức.

3.2.3. Huấn luyện mô hình và lựa chọn đặc trưng



Hình 3. 10: Quy trình lựa chọn đặc trưng từ các mô hình.

Sau khi trích xuất các đặc trưng từ tín hiệu sinh lý, bước tiếp theo là huấn luyện mô hình và lựa chọn đặc trưng quan trọng nhằm tối ưu hóa hiệu suất phân loại giữa hai trạng thái Cognitive Load và Rest được thực hiện theo quy trình ở hình 3.10 như sau:

- **Bước 1: Chuẩn bị dữ liệu huấn luyện và kiểm tra**

Tập dữ liệu được chia thành tập huấn luyện (training set) với 18 người (632 mẫu và 106 đặc trưng) và tập kiểm tra (test set) với 5 người (193 mẫu và 106 đặc trưng) bằng phương pháp Group K-Fold Cross-Validation nhằm đảm bảo rằng dữ liệu từ cùng một đối tượng không xuất hiện đồng thời ở cả hai tập. Đặc trưng đầu vào bao gồm đặc trưng thống kê và đặc trưng chuyên gia được trích xuất từ các tín hiệu sinh lý (GSR, RR, HR, Temp).

- **Bước 2: Lựa chọn mô hình**

Nghiên cứu tham khảo các mô hình từ cuộc thi UBIComp 2020[1] bao gồm 10 mô hình: SVM, Random Forest, XGBoost, Logistic Regression, CNN, RNN, MLP (Sklearn và Keras), Ensemble Of 7 Gradient Boosting Decision Tree, Weighted sum of individualized and global logistic regression models.

- **Bước 3: Lựa chọn đặc trưng quan trọng)**

Áp dụng SBS để loại bỏ các đặc trưng ít quan trọng, chỉ giữ lại các đặc trưng có đóng góp lớn vào việc phân loại. Mô hình có độ chính xác cao nhất sẽ được trích xuất.

3.2.4. Nhóm các đặc trưng theo từng tín hiệu sinh lý


Sau khi trích xuất và lựa chọn đặc trưng, các đặc trưng thống kê ban đầu được nhóm lại theo từng tín hiệu sinh lý gồm GSR, RR, HR, Temp để tạo cơ sở cho việc xây dựng mô hình Mạng Bayesian. Các đặc trưng thống kê được tính cho từng tín hiệu sinh lý nhằm mô tả sự biến đổi của tín hiệu trong khoảng thời gian nhất định. Nhóm này bao gồm các đặc trưng:

- Mean (Giá trị trung bình): Phản ánh xu hướng tổng thể của tín hiệu.
- Max - min (Phạm vi biến thiên): Đánh giá độ dao động của tín hiệu.

- Standard deviation (Độ lệch chuẩn - Std): Đo lường mức độ phân tán của tín hiệu.
- Skewness (Độ lệch): Đánh giá tính bất đối xứng của tín hiệu.
- Kurtosis (Độ nhọn): Đo lường mức độ tập trung của dữ liệu xung quanh giá trị trung bình.

Mục đích của việc phân nhó đặc trưng giúp cho việc đánh giá cấu trúc mạng xem nhóm nào đóng vai trò quan trọng hơn trong việc phân loại tín hiệu nhận thức. Ngoài nhóm các đặc trưng thống kê này ra chúng tôi sẽ nhóm các tín hiệu sau khi chọn được mô hình tốt nhất và kiểm tra từng nhóm đặc trưng được đưa vào.

3.2.5. Xây dựng mô hình Mạng Bayesian



Hình 3. 11: Quy trình xây dựng mô hình mạng Bayesian

Sau khi nhóm các đặc trưng theo tín hiệu sinh lý, bước tiếp theo là xây dựng mô hình Mạng Bayesian (Bayesian Network - BN) để phân loại trạng thái nhận thức (Cognitive Load và Rest) được thực hiện theo quy trình ở hình 3.11 như sau:

- **Bước 1: Xác định đầu vào cho Mạng Bayesian**


Mô hình BN được xây dựng dựa trên các nhóm tín hiệu được chọn ở mục 2.2.4 nhằm đảm bảo thông tin từ các tín hiệu sinh lý.

- **Bước 2 Xây dựng cấu trúc mạng Bayesian:**

Việc xây dựng cấu trúc mạng bao gồm việc xác định các nút trong mạng dựa trên các nhóm đặc trưng đã phân loại và xác định các mối quan hệ (edges) giữa các đặc trưng

dựa trên nghiên cứu trước đây về sự ảnh hưởng lẫn nhau của tín hiệu sinh lý. Theo nghiên cứu của Tervonan et al. (2021) [10], các tín hiệu sinh lý có mối quan hệ mật thiết với nhau và phản ánh trạng thái nhận thức của con người. Vì vậy, bước tiếp theo là xác định mối quan hệ giữa các tín hiệu sinh lý, giúp hiểu rõ hơn về cách chúng tương tác và ảnh hưởng lẫn nhau trong quá trình đánh giá tải nhận thức. Chúng tôi trực quan hóa bằng các tín hiệu ảnh hưởng đến nhau như mô tả ở hình 3.12. Cụ thể:

- Nhịp tim (HR) tăng khi mức độ căng thẳng hoặc tải nhận thức cao do hệ thần kinh giao cảm (SNS) bị kích hoạt mạnh hơn. Điều này thường dẫn đến nhịp thở (RR) giảm.
- RR giảm có thể là dấu hiệu của việc SNS chi phối tim và tuyến mô hôi, làm thay đổi mức độ hô hấp.
- Điện da (GSR) tăng do hoạt động của SNS khiến tuyến mô hôi hoạt động mạnh hơn.
- Nhiệt độ da (ST - Skin Temperature) giảm khi GSR tăng, do sự giãn nở mạch máu ngoại vi. Ngược lại, khi SNS giảm hoạt động (trạng thái phục hồi), ST có xu hướng tăng trở lại.



Hình 3. 12: Các tín hiệu sinh lý ảnh hưởng đến nhau

Cuối cùng, chúng tôi sẽ kiểm tra các trường hợp mà các tín hiệu sinh lý ảnh hưởng đến nhãn Cognitive Load và Rest. Dựa trên mối quan hệ giữa các tín hiệu đã được tổng hợp từ nghiên cứu trước đó, chúng tôi sẽ phân tích cách từng tín hiệu hoặc nhóm tín hiệu tác động đến trạng thái nhận thức.

- **Bước 3: Kiểm tra ảnh hưởng của cấu trúc mạng**

Sau khi xây dựng mô hình BN, tiến hành kiểm tra xem việc thay đổi các cạnh giữa các tín hiệu sinh lý có ảnh hưởng đến nhãn Cognitive Load/Rest. So sánh các cấu trúc mạng khác nhau để xác định mạng tối ưu nhất. Mục tiêu của quá trình này là xác định mối quan hệ quan trọng nhất giữa các tín hiệu sinh lý và nhãn, đồng thời tối ưu hóa cấu trúc mạng Bayesian nhằm đạt được hiệu suất dự đoán tốt nhất.

3.2.6. Đánh giá mô hình

Tiếp theo, chúng tôi sẽ đánh giá mô hình mạng Bayesian bằng phương pháp Group K-Fold Cross-Validation giúp chia dữ liệu thành k nhóm sao cho dữ liệu từ cùng một đối tượng không xuất hiện đồng thời trong cả tập huấn luyện và tập kiểm tra. Điều này giúp kiểm tra độ tổng quát của mô hình trên các nhóm độc lập. Về phần tiêu chí đánh giá:

- Accuracy: Đánh giá tỷ lệ dự đoán đúng của mô hình.
- ROC-AUC (Receiver Operating Characteristic - Area Under Curve): Đo lường khả năng phân biệt giữa hai trạng thái Cognitive Load và Rest, giúp đánh giá hiệu suất mô hình một cách toàn diện hơn so với chỉ số accuracy.

Kết quả đánh giá sẽ giúp xác định độ tin cậy của mô hình khi áp dụng vào dữ liệu thực tế, đồng thời hỗ trợ so sánh giữa các phương pháp chọn đặc trưng và cấu trúc mạng Bayesian khác nhau.

CHƯƠNG 4: THỰC NGHIỆM VÀ KẾT QUẢ

4.1. Quy trình thực nghiệm

Bảng 4. 1: Danh sách mô tả các thực nghiệm chính

Thực nghiệm	Nội dung thực nghiệm	Mục tiêu
1	Tìm mô hình có hiệu suất cao nhất	Đánh giá và so sánh các mô hình khác nhau để tìm mô hình có đặc trưng tối ưu dựa trên độ chính xác và đường cong ROC.
2	Xác định các nút và các cạnh	Gom nhóm các đặc trưng theo tín hiệu, phân tích ảnh hưởng của từng nhóm đặc trưng đối với mô hình Bayesian, và kiểm tra tác động của việc thêm các đặc trưng vào mô hình.
3	Kiểm tra ảnh hưởng của các biến quan sát đến biến mục tiêu	Xác định các biến quan sát, đánh giá hiệu suất mô hình khi chỉ sử dụng các biến quan sát quan trọng, và xác nhận mức độ ảnh hưởng của từng loại tín hiệu đến kết quả dự đoán.

Bảng 4.1 là danh sách thực nghiệm gồm ba thực nghiệm chính. Thực nghiệm đầu tiên nhằm tìm ra mô hình có hiệu suất cao nhất bằng cách đánh giá và so sánh các mô hình dựa trên độ chính xác và đường cong ROC. Thực nghiệm thứ hai tập trung vào việc gom nhóm các đặc trưng theo loại tín hiệu, phân tích ảnh hưởng của chúng đối với mô hình Bayesian và kiểm tra tác động khi thêm các đặc trưng. Cuối cùng, thực nghiệm thứ ba đánh giá ảnh hưởng của các biến quan sát đến biến mục tiêu, giúp xác định các tín hiệu quan trọng và đo lường hiệu suất mô hình khi chỉ sử dụng những biến này. Các thực nghiệm được đánh giá dựa trên độ chính xác (Accuracy) và đường cong ROC (Receiver Operating Characteristic). Dưới đây là cách tính hai chỉ số này:

- **Accuracy (Độ chính xác):** Độ chính xác đo lường tỷ lệ dự đoán đúng trên tổng số dự đoán. Công thức tính:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

- TP (True Positive): Số lượng mẫu dương tính được dự đoán đúng.
- TN (True Negative): Số lượng mẫu âm tính được dự đoán đúng.
- FP (False Positive): Số lượng mẫu âm tính bị dự đoán sai thành dương tính.
- FN (False Negative): Số lượng mẫu dương tính bị dự đoán sai thành âm tính.
- **ROC (Receiver Operating Characteristic) và AUC (Area Under Curve):**
Đường cong ROC biểu diễn mối quan hệ giữa TPR (True Positive Rate – Tỷ lệ dương tính thực) và FPR (False Positive Rate – Tỷ lệ dương tính giả). Công thức tính:

$$TPR = \frac{TP}{TP + FN}, FPR = \frac{FP}{FP + TN}$$

Giá trị AUC (Area Under Curve) của ROC đánh giá khả năng phân loại tổng thể của mô hình. AUC càng cao thì mô hình càng có khả năng phân loại tốt.

4.1.1. Thực nghiệm 1: Tìm mô hình có hiệu suất cao nhất.

Sau khi hoàn thành các bước tiền xử lý, huấn luyện và tối ưu hóa mô hình, các mô hình được tham khảo từ bài báo của Gjoreski cùng các cộng sự “Cognitive Load Monitoring With Wearables - Lessons Learned From a Machine Learning Challenge [1] được đánh giá dựa trên các chỉ số như độ chính xác, số lượng đặc trưng, đường cong ROC, ... với hai trường hợp như sau:

Trường hợp 1: Không sử dụng cửa sổ trung bình trượt

Bảng 4. 2: Đánh giá kết quả mô hình khi không sử dụng SMA.

Model	Features	Accuracy	ROC	F1-score	Precision	Recall
SVM	52	0.6788	0.69	0.66	0.71	0.62
XGB	85	0.7098	0.71	0.71	0.73	0.68
LR	11	0.7098	0.73	0.73	0.71	0.72
RF	21	0.7565	0.73	0.73	0.75	0.78
MLP (SKLearn)	25	0.6943	0.71	0.71	0.69	0.72
MLP (Keras)	11	0.5751	0.50	0.50	0.60	0.50
E7GB	24	0.7306	0.75	0.75	0.83	0.50
WGLR	31	0.7306	0.74	0.74	0.72	0.70
ESVM	16	0.7047	0.68	0.68	0.77	0.60
CNN	106	0.6010	0.61	0.62	0.60	0.63
RNN	106	0.6528	0.67	0.66	0.66	0.66


Trường hợp 2: Sử dụng cửa sổ trung bình trượt (window = 3)

Bảng 4. 3: Đánh giá kết quả mô hình khi sử dụng SMA (window = 3).

Model	Features	Accuracy	ROC	F1-score	Precision	Recall
SVM	29	0.6839	0.70	0.71	0.66	0.77
XGB	52	0.7150	0.73	0.72	0.72	0.72
LR	10	0.7089	0.75	0.75	0.67	0.84
RF	13	0.7513	0.74	0.77	0.72	0.83
MLP (SKLearn)	25	0.6943	0.70	0.71	0.69	0.72
MLP (Keras)	11	0.5751	0.65	0.54	0.60	0.50
E7GB	11	0.7098	0.74	0.72	0.71	0.72
WGLR	17	0.7306	0.73	0.76	0.69	0.85
ESVM	27	0.7202	0.73	0.69	0.78	0.62

CNN	100	0.5907	0.61	0.60	0.58	0.62
RNN	100	0.6269	0.67	0.62	0.64	0.60

Dựa vào kết quả bảng 4.2 và bảng 4.3, mô hình Random Forest (RF) đạt độ chính xác cao nhất là 75.65% với việc sử dụng 21 đặc trưng quan trọng trên 106 đặc trưng đã được trích xuất trong khi không sử dụng cửa sổ trung bình trượt.



Hình 4. 1: Đường cong ROC của các mô hình phân loại.

Xét về đường cong ROC ở hình 4.1, mô hình Random Forest đạt 73%, ngang bằng với Logistic Regression nhưng RF có độ chính xác cao hơn và có đường cong nghiêng về. Đường ROC càng hướng về phía điểm (0,1) thì mô hình phân loại càng tốt, gần như hoàn hảo, vì đây là điểm lý tưởng thể hiện TPR cao và FPR thấp. Mô hình E7GB có đường cong ROC cao nhất (0.75), tuy nhiên Recall chỉ đạt 0.50, cho thấy nó có xu

hướng dự đoán nhiều trường hợp dương tính nhưng dễ bỏ sót các trường hợp âm tính. Ngược lại, các mô hình CNN (ROC = 0.61) và RNN (ROC = 0.67) thấp hơn dẫn đến việc khả năng phân loại của chúng chưa thực sự tốt trên tập dữ liệu này. Dưới đây là bảng 4.4 mô tả 21 đặc trưng quan trọng được lựa chọn từ mô hình RF sau khi áp dụng lựa chọn đặc trưng SBS.

Bảng 4. 4: Các đặc trưng quan trọng được lựa chọn trong mô hình Random Forest.

Tín hiệu (số lượng đặc trưng)	Đặc trưng quan trọng
GSR (8 đặc trưng)	gsr_q75,min_SCR_Onsets,mean_SCR_Peaks, max_SCR_Height,min_SCR_Recovery, max_SCR_Recovery,mean_SCR_Recovery, max_SCR_RecoveryTime.
RR (11 đặc trưng)	rr_diff2, HRV_RMSSD, HRV_CVNN, HRV_MedianNN, HRV_HF _n , HRV_CSI_Modified, HRV_IALS, HRV_PAS, HRV_GI, HRV_AI, HRV_Cd.
Temp (2 đặc trưng)	temp_std, temp_skew.
HR	

4.1.2. Thực nghiệm 2: Xác định các nút và các cạnh.

Trong bước này, chúng tôi tiến hành nhóm các đặc trưng theo bốn tín hiệu sinh lý chính: GSR, RR, Temp, HR. Mỗi tín hiệu sẽ bao gồm các đặc trưng thống kê quan trọng như mean, std, max-min, skew, kurtosis. Ngoài ra, chúng tôi còn bổ sung thêm hai nhóm đặc trưng được chọn lọc từ kết quả thực nghiệm trước đó để tối ưu hóa mô hình.

Bảng 4. 5: Nhóm các đặc trưng vào các tín hiệu sinh lý.

Nhóm đặc trưng	Các đặc trưng được gom nhóm
HR_Features	mean, std, max-min, skew, kurtosis
RR_Features	mean, std, max-min, skew, kurtosis
GSR_Features	mean, std, max-min, skew, kurtosis
Temp_Features	mean, std, max-min, skew, kurtosis
RR_Selection	rr_diff2, HRV_RMSSD, HRV_CVNN, HRV_MedianNN, HRV_HF _n , HRV_CSI_Modified, HRV_IALS, HRV_PAS, HRV_GI, HRV_AI, HRV_Cd.
GSR_Selection	gsr_q75,min_SCR_Onsets,mean_SCR_Peaks, max_SCR_Height,min_SCR_Recovery, max_SCR_Recovery,mean_SCR_Recovery, max_SCR_RecoveryTime.

Quá trình nhóm đặc trưng như mô tả bảng 4.5 giúp làm rõ mối quan hệ giữa các tín hiệu sinh lý, đồng thời tạo điều kiện thuận lợi cho việc xây dựng cấu trúc mạng Bayesian. Các đặc trưng sau khi được nhóm sẽ được sử dụng để xác định các nút trong mạng Bayesian, còn các mối liên hệ giữa chúng sẽ hình thành các cạnh của mạng.

Chúng tôi lựa chọn những đặc trưng thống kê cho mỗi tín hiệu bao gồm std, mean, max-min, skew, kurtosis vì bản chất dữ liệu chúng tôi đang dùng là chuỗi thời gian và hệ thống cần nắm bắt được khoảng thời gian xác định nên các tín hiệu này sẽ là thông tin đầu vào trong việc xây dựng cấu trúc mạng này. Dữ liệu trong bài toán của tôi bao gồm các tín hiệu sinh lý liên tục như HR, GSR, Temp và RR. Sau khi trích xuất đặc trưng, các giá trị này vẫn ở dạng liên tục, gây khó khăn cho mô hình Bayesian trong việc học mối quan hệ giữa các biến. Do đó, tôi sử dụng thuật toán KBinsDiscretizer với (n_bins=2, encode='ordinal', strategy='quantile') để rời rạc hóa

dữ liệu như mô tả hình 4.2. Phương pháp này chia dữ liệu thành hai nhóm dựa trên phân vị và giúp cân bằng số lượng mẫu trong mỗi nhóm.


1	temp_mean	temp_std	temp_skew	temp_kurtosis	temp_diff
2	34.808001	0.006644	-3.5378904	12.43059431	0.001035
3	34.868	0.012972	1.1089357	-0.72090836	0.001034
4	34.951667	0.003582	1.8747163	1.840244407	0.000345
5	34.834334	0.004885	0.2830137	-1.99378115	0.000345
6	34.907333	0.006457	-2.2549249	3.62634392	0.00069
7	34.976667	0.004631	-0.743488	-1.47166545	-0.00034

→

1	temp_mean	temp_std	temp_skew	temp_kurtosis
2	1	1	0	0
3	1	0	1	1
4	1	1	1	1
5	1	0	1	1
6	1	0	1	1
7	1	0	1	1

Hình 4. 2: Dữ liệu được chuẩn hóa thành dữ liệu rời rạc.

Sau khi tìm mối quan hệ giữa các tín hiệu sinh lý ở mục 3.2.5 đã đề cập. Để trực quan hóa cấu trúc ban đầu của mạng Bayesian, chúng tôi sử dụng phương pháp GroupKFold (k=5) để đánh giá mô hình.



Hình 4. 3: Cấu trúc ban đầu của mô hình mạng Bayesian.

Với cấu trúc mạng này ta chúng tôi sử dụng phương pháp đánh giá là GroupKfold (k=5) để huấn luyện cấu trúc mạng. Kết quả thu được cho mô hình này là 62,69%. chúng tôi tiếp tục cải thiện mô hình bằng cách bổ sung thêm các nhóm đặc trưng quan

trọng từ thực nghiệm trước. Chúng tôi đã thêm từng nhóm đặc trưng sau khi được trích xuất với kết quả có được như sau.

Bảng 4. 6: Các thực nghiệm đưa các đặc trưng quan trọng vào từng nhóm.

Nhóm đặc trưng	Độ chính xác
- HR(5): HR_Features - RR(5): RR_Features - GSR(13): GSR_Features, GSR_Selection - Temp(5): Temp_Features	0.6269
- HR(5): HR_Features - RR(16): RR_Features, RR_Selection - GSR(5): GSR_Features - Temp(5): Temp_Features	0.6425
- HR(5): HR_Features - RR(16): RR_Features, RR_Selection - GSR(13): GSR_Features, GSR_Selection - Temp(5): Temp_Features	0.5907


Dựa vào kết quả bảng 4.6, chúng tôi thấy được việc đưa nhóm đặc trưng quan trọng đã được lựa chọn từ bảng 4.5 cho thấy được mô hình phân loại tốt khi bổ sung thêm các đặc trưng của nhóm tín hiệu RR với 64.25%. Việc thêm cùng lúc các đặc trưng quan trọng của RR và GSR có thể làm giảm độ chính xác do quá trình nhiễu hoặc overfitting.

4.1.3. Thực nghiệm 3: Kiểm tra ảnh hưởng của các biến quan sát đến biến mục tiêu bằng chiến lược vét cạn.

Bảng 4. 7: Kết quả thực nghiệm chiến lược vét cạn.


TRƯỜNG HỢP	CÁC TÍN HIỆU ẢNH HƯỞNG ĐẾN NHÃN	ĐỘ CHÍNH XÁC
1	HR	0.5544
2	RR	0.6010
3	GSR	0.5803
4	Temp	0.4819
5	HR-RR	0.6010
6	HR-GSR	0.5699
7	HR-Temp	0.5544
8	RR-GSR	0.6010
9	RR-Temp	0.6010
10	GSR-Temp	0.5803
11	HR-RR-GSR	0.6062
12	HR-RR-Temp	0.5803
13	HR-GSR-Temp	0.5544
14	RR-GSR-Temp	0.6580
15	HR-RR-GSR-Temp	0.6425

Dựa vào bảng 4.7, ta có thể thấy được nhóm biến quan sát ảnh hưởng đến biến mục tiêu được thử nghiệm. Kết quả cho thấy rằng, tầm quan trọng của RR, GSR, Temp ảnh hưởng như thế nào đối với biến mục tiêu trong việc phân loại tải nhận thức với độ chính xác cao nhất 65,8%. Điều này lý giải cho việc dựa trên nghiên cứu của Tervonan et al. (2021) [10] cho thấy ba tín hiệu đã được đề cập ảnh hưởng đến sự căng thẳng hoặc nghỉ ngơi trong tải nhận thức.



Hình 4. 4: Hiệu suất mô hình trên tập huấn luyện $GroupKFold = 5$.

Từ các thực nghiệm theo quy trình dựa trên phương pháp đề xuất như đã đề cập ở chương 3, chúng tôi thu được một mô hình mạng Bayesian trong việc phân loại tín hiệu nhận thức với độ chính xác là 65,8% và đường cong ROC là 66% (hình 4.4). Cấu trúc mạng Bayesian cuối cùng của nghiên cứu chúng tôi được mô tả hình 4.5.



Hình 4. 5: Cấu trúc mạng tối ưu cho tải nhận thức

4.2. Kết quả thực nghiệm

- Thực nghiệm 1: Mô hình Random Forest đạt độ chính xác cao nhất (75.65%), với diện tích dưới đường cong ROC (73%), sử dụng 21 đặc trưng quan trọng.
- Thực nghiệm 2: Mạng Bayesian ban đầu đạt độ chính xác (62.69%) khi sử dụng GroupKFold (k=5) và rời rạc hóa dữ liệu bằng KBinsDiscretizer. Sau đó bổ sung các nhóm đặc trưng được chọn từ thực nghiệm 1 vào, kết quả đạt được khả quan hơn với 64,25%.
- Thực nghiệm 3: Thực hiện chiến lược vét cạn cho các trường hợp mà các biến quan sát như tín hiệu sinh lý ảnh hưởng đến biến mục tiêu. Kết quả đạt được với độ chính xác 65,8% và đường cong ROC 66%.

Tóm lại, trong nghiên cứu “*Ứng dụng Mạng Bayesian trong việc phân loại tải nhận thức*”, mô hình Mạng Bayesian sau khi tối ưu hóa đạt độ chính xác 65,8% và diện tích dưới đường cong ROC (AUC-ROC) 66%, cải thiện đáng kể so với mô hình ban đầu. Sự cải thiện này có được nhờ việc lựa chọn các đặc trưng quan trọng, giúp mô hình tập trung vào những tín hiệu sinh lý có ảnh hưởng lớn đến tải nhận thức được thể hiện ở hình 4.6.


Các kết quả thực nghiệm cho thấy Mạng Bayesian có tiềm năng trong việc phân loại tải nhận thức, đặc biệt khi xem xét các tín hiệu độ dẫn điện da (GSR), tần số hô hấp (RR) và nhiệt độ cơ thể (Temp) – những yếu tố được chứng minh có tác động mạnh mẽ đến trạng thái nhận thức. Phát hiện này cũng phù hợp với nghiên cứu của Tervonen et al. (2021) [10], trong đó ba tín hiệu trên có mối liên hệ chặt chẽ với mức độ căng thẳng và trạng thái nghỉ ngơi.

Mặc dù hiệu suất của mô hình chưa vượt trội so với một số nghiên cứu trước đây, nhưng nghiên cứu này mang lại một góc nhìn mới về mối quan hệ nhân quả giữa các tín hiệu sinh lý và tải nhận thức. Thay vì chỉ tập trung vào độ chính xác thuần túy,

mô hình Mạng Bayesian giúp suy luận và diễn giải các mối liên kết giữa các tín hiệu, từ đó hỗ trợ giám sát mức tải nhận thức trong các hệ thống theo dõi sức khỏe.

Ứng dụng thực tế của nghiên cứu có thể giúp phát triển các hệ thống hỗ trợ ra quyết định và cảnh báo sớm, góp phần nâng cao hiệu suất làm việc, bảo vệ sức khỏe tinh thần và cải thiện sự tập trung trong các môi trường yêu cầu cường độ nhận thức cao.

COGNITIVE LOAD BAYESIAN NETWORK



Hình 4. 6: Cấu trúc mạng Bayesian được đề xuất trong nghiên cứu.

Dựa vào hình 4.6, ta có bảng xác suất có điều kiện $P(\text{Label}|\text{RR}, \text{GSR}, \text{Temp})$, có thể xác định trạng thái tải nhận thức dựa trên các tín hiệu sinh lý như nhịp thở (RR), độ dẫn điện da (GSR), và nhiệt độ da (Temp). Một ví dụ về tính toán xác suất có điều kiện trong mô hình Bayesian như sau:

$$P(\text{Label} = 0 | \text{GSR} = 0, \text{RR} = 0, \text{Temp} = 0) = \frac{\text{Số lượng mẫu } (\text{Label} = 0, \text{GSR} = 0, \text{RR} = 0, \text{Temp} = 0) + 2,542}{\text{Số lượng mẫu } (\text{GSR} = 0, \text{RR} = \text{Temp} = 0) + 3}$$

Với số liệu thực nghiệm, ta có:

$$P(\text{Label} = 0 | \text{GSR} = 0, \text{RR} = 0, \text{Temp} = 0) = \frac{31 + 2,542}{102 + 3} \approx 0.3194$$

Trong đó, 3 và 2.542 là chỉ số smoothing trong mô hình Bayesian Network của thư viện pmgpy, giúp tránh xác suất bằng 0 khi không có dữ liệu quan sát.

Kết quả từ bảng xác suất tải nhận thức $P(\text{Label} | \text{RR}, \text{GSR}, \text{Temp})$ cung cấp cái nhìn sâu sắc về mối quan hệ giữa ba tín hiệu sinh lý và trạng thái tải nhận thức của đối tượng. Dữ liệu cho thấy xác suất tải nhận thức không chỉ phụ thuộc vào từng tín hiệu riêng lẻ mà còn bị ảnh hưởng bởi sự kết hợp giữa chúng.

Cụ thể, khi nhiệt độ da (Temp) tăng lên, xác suất tải nhận thức có xu hướng cao hơn trong nhiều trường hợp, cho thấy yếu tố này có thể đóng vai trò quan trọng trong việc phản ánh sự thay đổi sinh lý khi đối tượng chịu tải nhận thức. Tuy nhiên, sự kết hợp giữa các tín hiệu không phải lúc nào cũng tuân theo một quy luật đơn giản. Ví dụ, khi cả ba tín hiệu đều ở mức cao ($\text{RR} = 1, \text{GSR} = 1, \text{Temp} = 1$), xác suất tải nhận thức chỉ đạt 0.39 thấp hơn một số trường hợp khác như ($\text{RR}=0, \text{GSR}=0, \text{Temp}=1$) xác suất 0.68. Điều này cho thấy có thể tồn tại các yếu tố điều tiết hoặc tương tác phi tuyến giữa các biến sinh lý mà mô hình cần xem xét thêm.

Những phát hiện này có ý nghĩa quan trọng trong việc phát triển các mô hình dự đoán tải nhận thức từ dữ liệu sinh lý. Việc chỉ dựa vào một tín hiệu duy nhất có thể không đủ chính xác, thay vào đó, cần xem xét sự kết hợp của nhiều yếu tố để đạt được hiệu suất dự đoán tốt hơn. Đồng thời, kết quả này cũng mở ra hướng nghiên cứu mới trong việc tối ưu hóa bộ đặc trưng sinh lý, có thể giúp cải thiện độ chính xác của các hệ thống theo dõi tải nhận thức trong các ứng dụng thực tế như giám sát hiệu suất làm việc để đưa ra đề xuất nhằm bảo vệ sức khỏe của con người.

4.3. So sánh với các mô hình công trình nghiên cứu

Các công trình nghiên cứu liên quan họ đã sử dụng nhiều phương pháp khác nhau trong việc nghiên cứu trên tập dữ liệu đang nghiên cứu trong đề tài này. Các phương pháp này được lấy từ cuộc thi UBIcomp2020 [1] và được mô tả ở hình 4.7.

Method	Preprocessing	Features	Feature Selection	Proposed Classifier
I	-	Handcrafted: general	Sequential backward floating search	Ensemble of 7 Gradient boosting decision trees
II	-	Handcrafted: features in [34]	-	Support vector machine
III	Standardization (subjectwise)	Handcrafted: general and domain-specific	Sequential forward floating search	Ensemble of support vector machines [33]
IV	Standardization	Handcrafted: general and domain-specific	-	Logistic regression
V	Min-max normalization (overall and subjectwise)	Handcrafted: general and domain-specific (partially automated)	Feature discovery platform	Random forest
VI	Standardization	Handcrafted: general and domain-specific	-	Weighted sum of individualized and global logistic regression models
VII	Min-max normalization	Handcrafted: general and domain-specific	Maximal information coefficient	Multilayer perceptron
VIII	-	Handcrafted: general and domain-specific	-	Logistic regression
IX	Standardization (subjectwise)	Handcrafted: general and domain-specific	Gini impurity	Support vector machine [37]
X	-	Handcrafted: correlation dimension	-	XGBoost classifier
XI	Standardization	Automated: pretrained on a larger dataset [35]	-	Convolutional neural network (6 layers per sensor data, each layer with batch normalization and ReLU activation)
XII	Min-max normalization (subjectwise)	Automated	-	Recurrent neural network [36]
XIII	Standardization (subjectwise)	Handcrafted: general and domain-specific	Gini impurity	Logistic regression

Hình 4. 7: Các phương pháp được những người tham gia trong cuộc thi UBIcomp2020.[1]

Các phương pháp này cho ra các kết quả như sau:

Bảng 4. 8: Kết quả độ chính xác của 13 phương pháp từ cuộc thi.[1]

CÁC PHƯƠNG PHÁP	ĐỘ CHÍNH XÁC
I	0.694
II	0.679
III	0.674
IV	0.663
BAYESIAN NETWORK	0.658
V	0.653
VI	0.653
VII	0.648
VIII	0.648
IX	0.627
X	0.580
XI	0.560
XII	0.554
XIII	0.503

Dựa vào kết quả trong Bảng 4.8, ta thấy rằng mô hình mạng Bayesian đạt độ chính xác 65,8%, xếp ở vị trí thứ IV và V. Kết quả này cho thấy mô hình có hiệu suất tương đối tốt so với các phương pháp khác, nhưng vẫn chưa đạt mức cao nhất (69,4%). Tuy nhiên, một ưu điểm quan trọng của mô hình mạng Bayesian là khả năng diễn giải mối quan hệ giữa các tín hiệu sinh lý và trạng thái tải nhận thức. Không giống như các phương pháp đề xuất khác vốn hoạt động như một “hộp đen”, mô hình Bayesian giúp ta hiểu được cách các đặc trưng sinh lý ảnh hưởng đến tải nhận thức, từ đó cung cấp cái nhìn sâu hơn về cơ chế hoạt động của hệ thống sinh lý.

KẾT LUẬN VÀ KHUYẾN NGHỊ

❖ Kết luận

Trong nghiên cứu này, chúng tôi đã xây dựng và đánh giá mô hình mạng Bayesian nhằm phân loại trạng thái tải nhận thức dựa trên các tín hiệu sinh lý. Các đặc trưng được trích xuất từ tín hiệu GSR, HR, RR và nhiệt độ đã được sử dụng để huấn luyện mô hình. Kết quả đánh giá trên tập dữ liệu thử nghiệm cho thấy mô hình đạt độ chính xác trung bình 65,8%, xếp hạng ở vị trí IV và V so với các phương pháp khác. Mặc dù chưa đạt được độ chính xác cao nhất, nhưng mô hình Bayesian có ưu điểm quan trọng là khả năng biểu diễn mối quan hệ giữa các tín hiệu sinh lý và trạng thái tải nhận thức, giúp hiểu rõ hơn về bản chất của dữ liệu thay vì chỉ hoạt động như một hộp đen.

So với các phương pháp khác, mô hình Bayesian không chỉ cung cấp dự đoán mà còn cho phép phân tích nguyên nhân và mức độ ảnh hưởng của từng tín hiệu đến kết quả cuối cùng. Điều này rất quan trọng trong nghiên cứu tải nhận thức, nơi mà việc diễn giải dữ liệu có thể cung cấp thông tin hữu ích cho các ứng dụng thực tế như đánh giá căng thẳng trong môi trường làm việc hoặc cải thiện hệ thống hỗ trợ ra quyết định.

❖ Hướng phát triển trong tương lai

Mặc dù nghiên cứu đã đạt được những kết quả khả quan, vẫn còn một số hướng phát triển cần được xem xét để cải thiện hiệu suất của mô hình:

- ❖ Áp dụng mô hình với tập dữ liệu khác: Tìm kiếm các tập dữ liệu liên quan đến tải nhận thức và áp dụng vào trong mô hình mạng Bayesian nhằm đánh giá hiệu suất đối với cấu trúc mạng này.
- ❖ Ứng dụng Gaussian Bayesian Network (GBN): Một hướng phát triển quan trọng là mở rộng mô hình Bayesian truyền thống sang Gaussian Bayesian

Network (GBN), giúp mô hình hóa tốt hơn các quan hệ giữa các biến liên tục. GBN có khả năng xử lý dữ liệu sinh lý một cách chính xác hơn bằng cách sử dụng phân phối Gauss để biểu diễn mối quan hệ giữa các tín hiệu. Điều này có thể cải thiện độ chính xác trong phân loại trạng thái tải nhận thức, đồng thời vẫn giữ được tính diễn giải của mô hình.

- ❖ **Kết hợp phương pháp đa tỉ lệ (Multi-Scale) với Bayesian Network:** Một cải tiến quan trọng khác là áp dụng phương pháp phân tích đa tỉ lệ để xử lý dữ liệu tín hiệu sinh lý trước khi đưa vào mô hình Bayesian. Dữ liệu sinh lý thường có tính chất không ổn định và biến đổi theo nhiều mức thời gian khác nhau. Việc sử dụng phương pháp đa tỉ lệ giúp trích xuất thông tin ở nhiều khung thời gian khác nhau (ví dụ: ngắn hạn, trung hạn và dài hạn), từ đó cung cấp thêm thông tin hữu ích cho mô hình Bayesian. Cách tiếp cận này không chỉ giúp cải thiện độ chính xác mà còn giữ được khả năng diễn giải, cho phép xác định mức ảnh hưởng của từng đặc trưng ở các mức thời gian khác nhau đến trạng thái tải nhận thức.

TÀI LIỆU THAM KHẢO

- [1] Gjoreski, M., Mahesh, B., Kolenik, T., Uwe-Garbas, J., Seuss, D., Gjoreski, H., Luštrek, M., Gams, M., & Pejović, V. (2021). Cognitive Load Monitoring With Wearables—Lessons Learned From a Machine Learning Challenge.
- [2] F. Schmalfu , S. Mach, K. Klüber, B. Habelt, M. Beggiato, A. Körner, and J. F. Krems, Potential of wearable devices for mental workload detection in different physiological activity conditions, in Proc. Hum. Factors Ergonom. Soc. Europe, 2018, pp. 179191.
- [3] O. Shaposhnyk and S. Yanushkevich, "Integration of Structural Equation Models and Bayesian Networks for Cognitive Load Modeling," 2023 IEEE Symposium Series on Computational Intelligence (SSCI), Mexico City, Mexico, 2023, pp. 1650-1655, doi: [10.1109/SSCI52147.2023.10372068](https://doi.org/10.1109/SSCI52147.2023.10372068).
- [4] J. Tervonen, K. Pettersson, and J. Mäntyjärvi, “Ultra-short window length and feature importance analysis for cognitive load detection from wearable sensors,” *Electronics*, vol. 10, no. 5, p. 613, Mar. 2021, doi: [10.3390/electronics10050613](https://doi.org/10.3390/electronics10050613).
- [5] Y. C. Cho and M. S. Kim, “Characteristics in HRV (heart rate variability), GSR (galvanic skin response) and skin temperature for stress estimate,” *Journal of the Korea Industrial Information Systems Research*, vol.20, no.3, pp.11-18, Jun.2015, doi: [10.9723/jksis.2015.20.3.011](https://doi.org/10.9723/jksis.2015.20.3.011).
- [6] F. Shaffer and J. P. Ginsberg, “An overview of heart rate variability metrics and norms,” *Frontiers in Public Health*, vol. 5, p. 258, Oct. 2017, doi: [10.3389/fpubh.2017.00258](https://doi.org/10.3389/fpubh.2017.00258).
- [7] H. D. Critchley, “Electrodermal responses: What happens in the brain, Neuroscientist”, vol.8, no.2, pp.132-142, Apr.2002, doi: [10.1177/107385840200800209](https://doi.org/10.1177/107385840200800209).
- [8] H. F. Posada-Quintero and K. H. Chon, “Phasic and tonic components of electrodermal activity: A review,” *Frontiers in Physiology*, vol. 11, p. 561305, Sep. 2020, doi: [10.3389/fphys.2020.561305](https://doi.org/10.3389/fphys.2020.561305).

- [9] Vadim Borisov, Enkelejda Kasneci, Gjergji Kasneci, “Robust cognitive load detection from wrist-band sensors”, doi: doi.org/10.1016/j.chbr.2021.100116.
- [10] Tervonen, J., Pettersson, K., & Mäntyjärvi, J. (2021). Ultra-short window length and feature importance analysis for cognitive load detection from wearable sensors. *Electronics*, 10(5), 613. doi: doi.org/10.3390/electronics10050613.
- [11] D. Koller and N. Friedman, *Probabilistic Graphical Models: Principles and Techniques*, 1st ed. Cambridge, MA, USA: MIT Press, 2009.
- [12] C. M. Bishop, *Pattern Recognition and Machine Learning*, 1st ed. New York, NY, USA: Springer, 2006.
- [13] F. V. Jensen, *Bayesian Networks and Decision Graphs*, 2nd ed. New York, NY, USA: Springer, 2001.
- [14] B. Mihaljevic, C. Bielza, and P. Larrañaga, “Bayesian networks for interpretable machine learning and optimization,” *Expert Systems with Applications*, vol. 171, p. 114591, Jun. 2021.
- [15] Mihaljević, B., Bielza, C., & Larrañaga, P. (2021). Bayesian networks for interpretable machine learning and optimization. *Expert Systems with Applications*, 168, 114455.
- [16] Heckerman, D. (1995). A tutorial on learning with Bayesian networks. *Microsoft Research Technical Report*.
- [17] Kruegel, C., & Toth, T. (2003). Using Bayesian networks to detect anomalous system behavior. *Proceedings of the 2003 IEEE Symposium on Security and Privacy*.
- [18] Paden, B., Čáp, M., Yong, S. Z., Yershov, D., & Frazzoli, E. (2016). A survey of motion planning and control techniques for self-driving urban vehicles. *IEEE Transactions on Intelligent Vehicles*, 1(1), 33-55.
- [19] Blei, D. M., Ng, A. Y., & Jordan, M. I. (2003). Latent Dirichlet Allocation. *Journal of Machine Learning Research*, 3, 993-1022.

- [20] Y. M. Lim, et al., “Using mouse and keyboard dynamics to detect cognitive stress during mental arithmetic,” in *Proc. Sci. and Inf. Conf.*, Springer, 2014.
- [21] C. Setz, et al., “Discriminating stress from cognitive load using a wearable EDA device,” *IEEE Trans. Inf. Technol. Biomed.*, vol. 14, no. 2, pp. 410–417, Mar. 2010.
- [22] N. Nourbakhsh, et al., “Using galvanic skin response for cognitive load measurement in arithmetic and reading tasks,” in *Proc. OZCHI*, 2012, pp. 420–423.
- [23] S. G. Hart, “Nasa-task load index (Nasa-TLX); 20 years later,” *Proc. Hum. Factors Ergon. Soc. Annu. Meet.*, vol. 50, no. 9, Oct. 2006.
- [24] M. Hertzum, "Reference Values and Subscale Patterns for the Task Load Index (TLX): A Meta-Analytic Review," *Ergonomics*, vol. 64, no. 2, pp. 1–14, Jan. 2021.
- [25] V. Borisov, E. Kasneci, and G. Kasneci, “Robust cognitive load detection from wrist-band sensors,” *Computers in Human Behavior Reports*, vol. 4, 2021, Art. no. 100116.
- [26] D. Jaiswal, D. Chatterjee, R. Gavas, R. K. Ramakrishnan, and A. Pal, “Effective assessment of cognitive load in real-world scenarios using wrist-worn sensor data,” in *Proc. BodySys’21: Workshop on Body-Centric Computing Systems*, Jun. 2021, pp. 7–12.